

# Claude Certified Architect — Foundations Certification

## مطالعہ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

### تعارف

سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر حقیقی Claude Certified Architect — Foundations Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) — یعنی بنیادی علم کا جائزہ لیتا ہے — کے ساتھ پروڈکشن ایپلیکیشنز بنائی جاتی ہیں۔ Claude و بنیادی ٹیکنالوجیز جن سے

agentic systems امتحانی سوالات حقیقت پسندانہ صنعتی منظرناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، ڈیزائن کرنا، Claude Code کو CI/CD میں ضم کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا۔

### هدف امیدوار

کرتا ہے آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات کے ساتھ کام، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

### امتحانی فارمیٹ

| پیرامیٹر         | قدر                                      |
|------------------|------------------------------------------|
| سوال کی قسم      | Multiple choice (میں سے 1 درست 4)        |
| اسکورنگ          | 100–1000 scale، passing score <b>720</b> |
| Guessing penalty | نہیں (سوال کا جواب دیں!)                 |
| Scenarios        | 8 4 (randomly selected) میں سے           |

## امتحانی مواد: 5 ڈومینز

| ڈومین                                       | وزن |
|---------------------------------------------|-----|
| 1. Agent architecture and orchestration     | 27% |
| 2. Tool design and MCP integration          | 18% |
| 3. Claude Code configuration and workflows  | 20% |
| 4. Prompt engineering and structured output | 20% |
| 5. Context management and reliability       | 15% |

## امتحانی منظر نامہ

### Scenario 1: Customer Support Agent

returns, billing disputes, اور account issues استعمال کرتے ہوئے Claude Agent SDK بناتے ہیں جو آپ ایک agent MCP tools (get\_customer, lookup\_order, process\_refund, escalate\_to\_human) سنبھالتا ہے۔ مناسب first-contact resolution +% استعمال کرنا 80 دفعہ ساتھ ساتھ escalation کے ساتھ ساتھ۔

### Scenario 2: Claude Code ساتھ Code Generation

code generation, refactoring, تیز کرنے کے لیے استعمال کرتے ہیں development کو Claude Code آپ کے ساتھ CLAUDE.md configuration اور custom slash commands آپ کو اسدے debugging, documentation کے ساتھ integrate کب استعمال کرنا planning mode کرنا، اور یہ سمجھنا کے

### Scenario 3: Multi-Agent Research System

tasks کو coordinator agent specialized subagents سونپتا: web research, document analysis, synthesis, تیار کرنے چاہئیں reports کے ساتھ مکمل citations سسٹم کو report generation اور

### Scenario 4: Developer Productivity Tools

agent engineers کو unfamiliar codebases explore کرنے، boilerplate code اور routine tasks بنانے، MCP servers اور Built-in tools (Read, Write, Bash, Grep, Glob) میں مدد دیتا ہے۔ automate کیے جاتے ہیں

### Scenario 5: Claude Code for Continuous Integration

pull اور automated code reviews, test generation, Claude Code کو CI/CD pipeline تاکہ کم سے کم false positives ڈیزائن ہونے چاہئیں کے Prompts حاصل ہو۔ request feedback

## Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے اور کو درست طور پر سنبھالنا چاہیے۔ edge cases پر برقرار رکھتا ہے اس high accuracy اور

## Scenario 7: Conversational AI Architecture Patterns

multi-turn conversational systems میں جن میں context window management، turns متعدد، memory strategies، tool design کے لیے execution محفوظ، کا برقرار رکھنا instructions میں اور مہم یا متضاد، user inputs کو سنبھالنا شامل ہے۔

## Scenario 8: Agentic AI Tools (ہماری مدد کریں — مواد موجود نہیں)

میں شامل نہیں ہے۔ guide نہ دی لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس کریں share میں GitHub Issues کے سوالات دیکھیں، تو ان میں scenario ہے اگر آپ نہ اصل امتحان میں اس شامل کر سکیں آپ کا تعاون۔ اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ ہم مکمل رہے۔

## سرکاری دستاویزات

| وسیلہ                                       | URL                                                                                                                                                       |
|---------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Claude API — Messages                       | <a href="https://platform.claude.com/docs/en/api/messages">https://platform.claude.com/docs/en/api/messages</a>                                           |
| Claude API — Tool Use                       | <a href="https://platform.claude.com/docs/en/build-with-claude/tool-use">https://platform.claude.com/docs/en/build-with-claude/tool-use</a>               |
| Claude API — Message Batches                | <a href="https://platform.claude.com/docs/en/build-with-claude/message-batches">https://platform.claude.com/docs/en/build-with-claude/message-batches</a> |
| Claude Agent SDK — Overview                 | <a href="https://platform.claude.com/docs/en/agent-sdk/overview">https://platform.claude.com/docs/en/agent-sdk/overview</a>                               |
| Claude Agent SDK — Hooks                    | <a href="https://platform.claude.com/docs/en/agent-sdk/hooks">https://platform.claude.com/docs/en/agent-sdk/hooks</a>                                     |
| Claude Agent SDK — Subagents                | <a href="https://platform.claude.com/docs/en/agent-sdk/subagents">https://platform.claude.com/docs/en/agent-sdk/subagents</a>                             |
| Claude Agent SDK — Sessions                 | <a href="https://platform.claude.com/docs/en/agent-sdk/sessions">https://platform.claude.com/docs/en/agent-sdk/sessions</a>                               |
| Model Context Protocol (MCP)                | <a href="https://modelcontextprotocol.io/">https://modelcontextprotocol.io/</a>                                                                           |
| MCP — Tools                                 | <a href="https://modelcontextprotocol.io/docs/concepts/tools">https://modelcontextprotocol.io/docs/concepts/tools</a>                                     |
| MCP — Resources                             | <a href="https://modelcontextprotocol.io/docs/concepts/resources">https://modelcontextprotocol.io/docs/concepts/resources</a>                             |
| MCP — Servers                               | <a href="https://modelcontextprotocol.io/docs/concepts/servers">https://modelcontextprotocol.io/docs/concepts/servers</a>                                 |
| Claude Code — Documentation                 | <a href="https://code.claude.com/docs/en/overview">https://code.claude.com/docs/en/overview</a>                                                           |
| Claude Code — CLAUDE.md and Memory          | <a href="https://code.claude.com/docs/en/memory">https://code.claude.com/docs/en/memory</a>                                                               |
| Claude Code — Skills (incl. slash commands) | <a href="https://code.claude.com/docs/en/skills">https://code.claude.com/docs/en/skills</a>                                                               |

|                                               |                                                                                                                                                                                   |
|-----------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Claude Code — Hooks                           | <a href="https://code.claude.com/docs/en/hooks">https://code.claude.com/docs/en/hooks</a>                                                                                         |
| Claude Code — Sub-agents                      | <a href="https://code.claude.com/docs/en/sub-agents">https://code.claude.com/docs/en/sub-agents</a>                                                                               |
| Claude Code — MCP Integration                 | <a href="https://code.claude.com/docs/en/mcp">https://code.claude.com/docs/en/mcp</a>                                                                                             |
| Claude Code — GitHub Actions CI/CD            | <a href="https://code.claude.com/docs/en/github-actions">https://code.claude.com/docs/en/github-actions</a>                                                                       |
| Claude Code — GitLab CI/CD                    | <a href="https://code.claude.com/docs/en/gitlab-ci-cd">https://code.claude.com/docs/en/gitlab-ci-cd</a>                                                                           |
| Claude Code — Headless (non-interactive mode) | <a href="https://code.claude.com/docs/en/headless">https://code.claude.com/docs/en/headless</a>                                                                                   |
| Prompt Engineering Guide                      | <a href="https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview">https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview</a> |
| Extended Thinking                             | <a href="https://platform.claude.com/docs/en/build-with-claude/extended-thinking">https://platform.claude.com/docs/en/build-with-claude/extended-thinking</a>                     |
| Anthropic Cookbook (code examples)            | <a href="https://github.com/anthropics/anthropic-cookbook">https://github.com/anthropics/anthropic-cookbook</a>                                                                   |

## نظریاتی بنیادیں: حصہ ۱

یہ حصہ تمام نظریاتی احاطہ کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو کے مطابق — اس سے آپ کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts ٹیکنالوجیز اور موضوع کی زیادہ گہری سمجھ پیدا کر سکتے ہیں۔

## کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

### 1.1 API Request Structure

Claude API کی request کی ر Claude Messages API کی پیروی کرتا ہے request–response model ایک شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"},
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

### م فیلڈر:

- `model` — model selection ( `claude-opus-4-6` , `claude-sonnet-4-6` , `claude-haiku-4-5` )
- `max_tokens` — response کی تعداد میں زیادہ سے زیادہ
- `system` — system prompt (model کی تعریف کرتا ہے)
- `messages` — conversation history (تاریخہ آپ کو مکمل کے لئے)
- `tools` — tools کی definitions دستیاب
- `tool_choice` — tool selection strategy

## 1.2 Message Roles

`messages` array میں roles استعمال کرتا ہے:

- `user` — user messages
- `assistant` — model responses (history میں شامل کیا جاتا ہے)
- `tool` — tool call results (role واضح طور پر `tool_result` میں کیا جاتا ہے؛ `set` میں ظاہر ہوتا ہے)

Model requests بھیجی جائے گی۔ `conversation history` میں آپ کو مکمل API request انتہائی اہم: ہر آزاد ہوتا ہے call محفوظ نہیں رکھتا — ہر state درمیان

## 1.3 Response میں `stop_reason` Field

کیوں روکی generation model شامل ہوتا ہے، جو بتاتا ہے کہ `stop_reason` میں Claude API response

| Value           | Description                   | Action                                             |
|-----------------|-------------------------------|----------------------------------------------------|
| "end_turn"      | Model نے response مکمل کر لیا | user کو دکھائیں نتیجہ                              |
| "tool_use"      | Model tool call کرنا چاہتا ہے | Tool execute کریں اور result دیں                   |
| "max_tokens"    | Token limit ختم ہو گئی        | Response truncated ہو سکتا ہے؛ limit بڑھانی پڑے گی |
| "stop_sequence" | Stop sequence مل گئی          | کریں handle کہ مطابق application logic اپنی        |

کو کنٹرول کرتے agent loop سب سے اہم ہیں — یہی "end\_turn" اور "tool\_use" میں Agentic systems ہیں۔

## 1.4 System Prompt

System prompt متعین کرتا ہے behavioral rules اور context جو instruction ایک خاص

- messages array الگ ہوتا؛ یہ system field کا حصہ نہیں ہوتا؛ بلکہ الگ array
- user messages پر فوقیت رکھتا ہے
- میں لاگو رہتا ہے conversation ہوتا ہے اور پوری load ایک بار
- کی تعریف کے لیے استعمال ہوتا ہے output format اور role, constraints,

پیدا کر سکتی ہے مثال کے طور پر tool associations غیر ارادی wording کی system prompt: امتحان کے لیے اہم کو ضرورت سے زیادہ get\_customer کو model کی تصدیق کریں "جیسی ہدایت customer پر،" ہمیشہ استعمال کرنے پر مجبور کر سکتی ہے، حتیٰ کے جب یہ ضروری نہ ہو

## 1.5 Context Window

Context window text (tokens) جسے اس میں process ایک وقت میں model کی کل مقدار ہے جسے شامل ہے:

- System prompt
- message history مکمل
- Tool definitions
- Tool results

مسائل context-window:

1. **Lost-in-the-middle effect:** models input سے اعتماد سے زیادہ موجود معلومات پر اختتام پر موجود معلومات کو زیادہ input سے اعتماد سے زیادہ models process کر سکتے ہیں۔ حل: اہم معلومات شروع یا آخر کے قریب miss کرتے ہیں، مگر درمیان کی تفصیلات process رکھیں
2. **Tool results** واپس کر کے 40+ fields tool شامل کرتا ہے اگر output میں tool call context کا جمع ہونا: ہر Tool results کا بڑا حصہ ضائع ہو جاتا ہے context مگر صرف 5 اہم ہوں، تو
3. **Progressive summarization:** history compress کرتے وقت numeric values, percentages, اور dates اکثر گم ہو کر غیر واضح ہو جاتے ہیں ("تقریباً"، "کچھ"، "چند")

## 2 Tools اور tool\_use: باب

Tool Use: دستاویزات

## 2.1 tool\_use کیا

برا Model کی اجازت دیتا external functions call Claude جو mechanism ایک tool\_use result کرتا اور execute اس code بناتا؛ آپ کا structured tool call request میں چلاتا — و code راست واپس کرتا

## 2.2 Tool Definition

کیا جاتا define کے ذریعہ JSON schema ایک tool

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

کے انتہائی اہم ہلو Tool description

- Description tool selection** کی بنیاد پر descriptions کو ان کی LLM tools mechanism کا انتخاب کرتا Minimal descriptions ("Customer information retrieve کرتا) اُن مواقع پر غلطیوں کا (کرتا) overlap کے ایک دوسرے tools باعث بنتی ہیں جب کرتے ہوں
- Description میں شامل کریں:**
  - کیا کرتا اور کیا واپس کرتا Tool
  - Input formats اور example values
  - Edge cases اور constraints
  - مقابلہ میں کب استعمال و tool similar alternatives
- کی analyze\_document اور analyze\_content سے بچیں اگر overlapping descriptions ایک جیسے یا انہیں خلط ملط کر دے گا model تقریباً ایک جیسی ہوں، تو descriptions
- Built-in tools** MCP tools: agents similar functionality والے built-in tools (Read, Grep) کو MCP tools — مضبوط بنائیں MCP tool descriptions پر ترجیح دے سکتے ہیں اس سے بچنے کے لیے tools advantages, unique data, context یا و built-in tools میں کر سکتے ہیں جو

## 2.3 tool\_choice Parameter

کیسے منتخب کرتا model tools کے کنٹرول کرتا tool\_choice

| Value                                                       | Behavior                                                      | کب استعمال کریں                                    |
|-------------------------------------------------------------|---------------------------------------------------------------|----------------------------------------------------|
| <code>{ "type": "auto" }</code>                             | Model کرنا tool call خود ط کرتا یا کرنا text یا میں جواب دینا | default زیاد تر حالات میں                          |
| <code>{ "type": "any" }</code>                              | Model کرنا tool call کو لازماً کوئی                           | guaranteed جب آپ کو structured output چاہیں        |
| <code>{ "type": "tool", "name": "extract_metadata" }</code> | Model کرنا tool call کو لازماً ایک مخصوص tool کو              | forced first step / execution order جب آپ کو چاہیں |

ا: م منظر نامہ:

- `tool_choice: "any"` + multiple extraction tools → model منتخب کرتا ہے، مگر پھر بھی tool بہترین model ملنا structured output
- Forced selection → enrichment (مثلاً) کی ضمانت چاہیں action جب آپ کو کسی خاص پم ( `extract_metadata` )

## 2.4 Structured Output JSON Schemas

حاصل کرنے کا سب سے قابلِ structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas

اعتماد طریقہ کے:

- Syntax (trailing commas، غائب ہیں، braces) کی ضمانت دیتا ہے JSON کے اعتبار سے درست (وٹ)
- (موجود وٹ ہیں required fields) نافذ کرتا ہے structure مطلوب
- Semantic correctness (values) کی ضمانت نہیں دیتا

Schema design — بنیادی اصول:

```
{
  "type": "object",
  "properties": {
    "category": {
      "type": "string",
      "enum": ["bug", "feature", "docs", "unclear", "other"]
    },
    "category_detail": {
      "type": ["string", "null"],
      "description": "Details if category = 'other' or 'unclear'"
    },
    "severity": {
      "type": "string",
      "enum": ["critical", "high", "medium", "low"]
    },
    "confidence": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "optional_field": {
      "type": ["string", "null"],
      "description": "Null if the information was not found in the source"
    }
  },
  "required": ["category", "severity"]
}
```

**Schema design rules:**

1. **Required** □ **optional:** □ **میشد** □ دستیاب □ **required** □ **fields** کو صرف اُن □ **مقیاب** □ **Required fields** model پر data کو □ **values** □ **غائب** □ **ون** □ **پر** □ **مجبور** کر سکتی □ **یں** □ **گھڑن** □
2. **Nullable fields:** □ ایسی معلومات □ **لی** □ **"type": ["string", "null"]** □ **استعمال** کریں جو ممکن □ **طور** □ **پر** □ **بجائ** □ **اس** □ **ک** □ **و** □ **خود** □ **ساخت** □ **null** □ **Model** □ **موجود** □ **ن** □ **وں** □ **بنا** □ **کر** □ **سکتا** □ **و** □ **value** □ **واپس** □ **کر** □ **سکتا** □ **ہو** □ **نہ** □ **نہ** □ **وں** □ **سد** □ **بجائ** □ **ک** □ **لی** □ **predefined categories** □ **اپنی** □ **Enums with "other":** □ **شامل** □ **کریں** □ **string** □ **ایک** □ **+** □ **"other"** □
3. **Enums with "other":** □ **شامل** □ **کریں** □ **string** □ **ایک** □ **+** □ **"other"** □
4. **Enum "unclear":** □ **بار** □ **میں** □ **پُر** □ **اعتماد** □ **نہ** □ **و** □ **ایماندار** □ **model category** □ **اُن** □ **صورتوں** □ **ک** □ **لی** □ **جب** □ **سد** □ **بتر** □ **□□□** □ **category** □ **غلط** □ **"unclear"** □


## 2.5 Syntax □ بمقابلہ Semantic Errors

| Error type | Example                                                | Mitigation                                                 |
|------------|--------------------------------------------------------|------------------------------------------------------------|
| Syntax     | Invalid JSON، field غلط type                           | JSON schema کے ساتھ tool_use (ختم کر دینا) (               |
| Semantic   | Totals match نہیں کرتے، value field غلط، hallucination | Validation checks، feedback کے ساتھ retry، self-correction |



## 3.3 Hub-and-Spoke: Coordinator اور Subagents

Multi-agent architecture عموماً hub-and-spoke topology میں بنائی جاتی ہے:



Coordinator کی ذمہ داریاں:

- Task کو subtasks میں تقسیم کرنا
- (dynamic selection) درکار subagents میں سے طے کرنا کہ کون سا
- کو سونپنا subagents کام
- کرنا validate نتائج جمع اور
- Errors اور retries handle کرنا
- تک پہنچانا user نتائج

الگ ہوتا context subagents کا: اصول

- Subagents conversation history کی coordinator خود بخود inherit نہیں کرتے
- میں واضح طور پر دینا ہوتا context subagent prompt تمام ضروری
- Subagents memory share کرتے ہیں کہ درمیان
- (observability اور error control) کے ذریعے گزرتی coordinator communication تمام

## 3.4 Subagents کے لیے Task Tool بنانا

Subagents Task tool کے ذریعے spawn میں جاتے ہیں:

```
# Coordinator میں allowedTools کے "Task" ہونا چاہیے
coordinator_agent = AgentDefinition(
    allowed_tools=["Task", "get_customer"]
)
```

Explicit context passing لازمی ہے:

```
# Bad: subagent کے پاس context نہیں ہے
Task: "Analyze the document"

# Good: context prompt مکمل
Task: "Analyze the following document.
Document: [full document text]
Prior search results: [web search results]
Output format requirements: [schema]"
```

**Parallel spawning:** coordinator ایک response میں متعدد Task s call کر سکتا ہے — subagents parallel چلتے ہیں:

```
# Coordinator کے ایک response میں شامل ہے
Task 1: "Search for articles about X"
Task 2: "Analyze document Y"
Task 3: "Search for articles about Z"
# تینوں ایک ساتھ چلتے ہیں
```

## 3.5 Agent SDK میں Hooks

Hooks agent lifecycle میں transformation اور interception پر points کے مخصوص

PostToolUse tool result کو model سے intercept تک پہنچانے سے پہلے model کو PostToolUse

```
# کریں formats normalize سے تاریخ کے MCP tools مثال: مختلف
@hook("PostToolUse")
def normalize_dates(tool_result):
    # Unix timestamp -> ISO 8601
    # "Mar 5, 2025" -> "2025-03-05"
    return normalized_result
```

Outgoing-call interception hook policy والے block کو actions کی خلاف ورزی کرنے والے

```
# کریں refunds block مثال: 500$ سے اوپر
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

Hooks اور prompt instructions میں فرق

| Attribute       | Hooks                                                     | Prompt instructions                              |
|-----------------|-----------------------------------------------------------|--------------------------------------------------|
| Guarantee       | Deterministic (100%)                                      | Probabilistic (>90%, 100% نہیں)                  |
| کب استعمال کریں | Critical business rules, financial operations, compliance | General preferences, recommendations, formatting |
| مثال            | Refunds > \$500 block کریں                                | "Try to solve before escalating"                 |

استعمال کریں hooks، انہیں prompts — کے مالی، قانونی، یا حفاظتی نتائج کے failure قاعدے: جب

## 4: Model Context Protocol (MCP)

دستاویزات: [MCP](#) | [Tools](#) | [Resources](#) | [Servers](#)

## 4.1 MCP کیا ہے

MCP (Model Context Protocol) Claude کو external systems سے جوڑتا ہے جو open protocol ایک ہے۔ MCP resource types define تین بنیادی کرتا ہے:

1. **Tools** — functions (agent actions) کے لیے call انجام دینے کے لیے (CRUD operations, API calls, command execution)
2. **Resources** — context کے لیے agent کے لیے (documentation, database schemas, content catalogs)
3. **Prompts** — predefined prompt templates کے لیے tasks عام

## 4.2 MCP Servers

MCP server ایک process جو MCP protocol implement کرتا ہے اور tools/resources جب فراہم کرنا چاہے۔ آپ MCP server سے connect کر سکتے ہیں:

- وہ خود بخود tools discover کریں گے
- ایک ساتھ دستیاب ہونے والے tools کے connected servers تمام
- انہیں کیسے استعمال کرنا ہے گا model طے کرتی ہے

## 4.3 MCP Servers کو Configure کرنا

Project configuration ( `.mcp.json` ) — team usage کے لیے:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {
        "GITHUB_TOKEN": "${GITHUB_TOKEN}"
      }
    },
    "jira": {
      "command": "npx",
      "args": ["-y", "mcp-server-jira"],
      "env": {
        "JIRA_TOKEN": "${JIRA_TOKEN}"
      }
    }
  }
}
```

ملاحظات:

- میں ہوتا ہے version control میں محفوظ ہوتا ہے اور `.mcp.json` project root
- Environment variables ( `${GITHUB_TOKEN}` ) secrets میں استعمال ہوتے ہیں۔ انہیں کیے جاتے ہیں



- Database schemas (data structure سمجھنے کے لیے)
- Documentation (API references, internal guides)
- Issue/task summaries

Resource کا فائدہ: agent کے لیے exploratory tool calls میں پڑتی کے سمجھنے کے لیے agent کا فائدہ: Resource کا فائدہ: map فوری Resource کیا ہے

## 5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

### 5.1 CLAUDE.md Hierarchy

hierarchy استعمال کرتا ہے اس کی تین سطحی Claude Code میں جو instruction file(s) و CLAUDE.md ہے:

1. User-level: ~/.claude/CLAUDE.md
  - پر لاگو user صرف اسی
  - نمونہ ہوتا ہے share کہ ذریعہ VCS
  - working style اور preferences ذاتی
2. Project-level: .claude/CLAUDE.md یا root CLAUDE.md
  - پر لاگو project contributors تمام
  - ہوتا ہے manage کہ ذریعہ VCS
  - Coding standards, testing standards, architectural decisions
3. Directory-level: subdirectories میں CLAUDE.md
  - کہ ساتھ کام ہو تو لاگو ہوتا ہے files کی directory جب اسی
  - conventions کہ اُس حصہ کہ مخصوص codebase

~/.claude/CLAUDE.md میں ملتی ہیں کیونکہ وہ project instructions کو team member عام غلطی: ایک نئے میں رکھی گئی تھیں (user-level) ~/.claude/CLAUDE.md (project-level) کے بجائے

### 5.2 @path Syntax (File Imports)

جو جاتی configuration modular کر سکتا ہے، جس سے refer کے ذریعہ @path کو files بیرونی CLAUDE.md ہے:

Coding standards @./standards/coding-style.md میں بیان کیے گئے ہیں  
 Test requirements @./standards/testing-requirements.md میں ہیں  
 Project overview @README.md اور dependencies @package.json میں ہیں

- (نہ) میں space کوئی) آئے file path کے فوراً بعد @
- Relative اور absolute دونوں paths supported ہیں
- Relative paths کے مطابق file اُس resolve کے میں جس میں import کے وئے ہیں
- Maximum import nesting depth 5 ہے

شامل ہوتے ہیں، standards میں صرف متعلقہ package کم ہوتی ہے اور duplication اس سے

کرنے کے organize کے حساب سے topic کو rules کا متبادل ہے، جو monolithic CLAUDE.md .claude/rules/

لیہ استعمال ہوتا ہے:

```
.claude/rules/  
  testing.md          -- testing conventions  
  api-conventions.md  -- API conventions  
  deployment.md       -- deployment rules  
  react-patterns.md   -- React patterns
```

```
---
paths: ["src/api/**/*.json"]
---
```

```
---
paths: ["**/*.test.tsx", "**/*.test.ts"]
---
```

استعمال ہونہ چاہئیں۔ describe/it blocks میں Tests  
 ہمیں، hardcoding استعمال کریں Data factories  
 استعمال کریں، test database - نہ کریں Database mock

۱۰. کس کا کام کرتا ہے؟

- کرتا match سہ pattern paths کر جو file edit ایسا Claude Code ہوتا ہے جب load صرف اس وقت Rule ہو
- نہیں ہیں rules load ہوتا ہے — غیر متعلقہ tokens اور context اس سہ
- Glob patterns کرنے دینے ہیں، چاہے conventions apply کے لحاظ سہ file type آپ کو میں codebase files (tests, migrations) پر (کے لیے بہت مفید tests) کے ہیں بھی ہوں

کے استعمال کریں directory-level CLAUDE.md بمقابلہ .claude/rules/ والے paths

- .claude/rules/ with paths — جب conventions کئی directories میں بکھری files (tests, migrations) پر لاگو ہوں
- Directory-level CLAUDE.md — جب conventions کسی خاص directory اور کے ہیں اور کے ہیں ضروری نہیں ہوں

## 5.4 Custom Slash Commands اور Skills

skills کو (.claude/commands/) custom commands میں Claude Code version نوٹ: موجود ہے بناؤ commands /name formats کر دیا گیا ہے دونوں unify کے ساتھ (.claude/skills/) supported اب بھی format کا ذکر کرتی ہے — و (.claude/commands/) ہیں امتحانی گائیڈ

Slash commands reusable prompt templates ہیں جو /name کے ذریعے invoke کے ہیں:

**.claude/commands/ format (legacy, supported):**

```
.claude/commands/
review.md      -- /review -- standard code review
test-gen.md    -- /test-gen -- test generation
```

**.claude/skills/ format (current):**

```
.claude/skills/
review/SKILL.md -- /review -- frontmatter configuration
test-gen/SKILL.md
```

**Project commands** (.claude/commands/ یا .claude/skills/):

- کرنے والے سب کے لیے دستیاب ہوتا ہے ہیں repo clone میں محفوظ ہوتا ہے ہیں اور VCS
- یقینی بنانا ہے consistent workflows میں

**User commands** (~/.claude/commands/ یا ~/.claude/skills/):

- نہیں ہیں ہوتا ہے share کے ذریعے VCS جو commands ذاتی
- کے لیے workflows انفرادی

## 5.5 Skills — .claude/skills/

Skills advanced commands ہیں جو SKILL.md frontmatter کے ذریعے configure کے ہیں:

```
---
context: fork
allowed-tools: ["Read", "Grep", "Glob"]
argument-hint: "Path to the directory to analyze"
---
```

کا تجزیہ کریں۔ code structure میں directory دی گئی  
report پر ایک architectural patterns اور Dependencies

#### Frontmatter parameters:

| Parameter                                  | Description                                                                                                          |
|--------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| <code>context:</code><br><code>fork</code> | Verbose output main session کو pollute کرتا isolated subagent کو Skill                                               |
| <code>allowed-tools</code>                 | نہیں کر skill files delete مثلاً — security) دستیاب ہوں گے tools یہ محدود کرتا کہ کون سے<br>(سکے گی اگر اجازت نہ ہو) |
| <code>argument-hint</code>                 | مانگنے کا اشارہ argument کو تو invoke کے بغیر skill parameters جب                                                    |

#### Skill `CLAUDE.md` کے استعمال کریں:

- Skill — task مخصوص — on-demand invocation (review, analysis, generation) کے لیے
- `CLAUDE.md` — general standards اور conventions کو ہمیشہ لوڈ ہونے والے —

#### Personal skills ( `~/claude/skills/` ):

- متاثر نہ ہوں teammates مختلف ناموں سے بنائیں تاکہ personal variants اپنی

## 5.6 Planning Mode `Direct Execution` کے مقابلے

#### Planning mode:

- Model نہایت کرتا changes؛ plan اور investigate صرف
- Codebase explore کے لیے Read، Grep، Glob استعمال کرتا
- کرتا user approve تیار کرتا جسے implementation plan ایک
- safe exploration کے side effects بغیر

#### Planning mode کے استعمال کریں:

- changes (files درجنوں) بڑے
- Multiple plausible approaches (microservices: boundaries کیسے define ہوں؟)
- Architectural decisions (کیا framework کون سا؟ structure؟)
- Unfamiliar codebase (change کی ضرورت ہے؟ سمجھنا ضروری ہے؟)
- Library migrations 45+ files کو متاثر کریں

#### Direct execution کے استعمال کریں:

- Single-file fixes ساتھ stack trace واضح
- شامل کرنا validation check ایک
- changes اچھی طرح سمجھ گئی، غیر مبہم

#### Combined approach:

1. Investigation اور design لیے planning mode
2. User plan approve کر
3. Approved plan implement لیے direct execution کرنے

#### Explore subagent — codebase explore لیے specialized subagent:

- Verbose output کو main context سے isolate کرنا
- واپس کرنا summary صرف
- روکنا Multi-phase tasks میں context-window exhaustion

## 5.7 /compact Command

/compact context compress لیے built-in command:

- میں جگہ خالی کرنا context window کو summarize کر کے history چھپی
- Long investigation sessions جب verbose tool output سے context بھر جائے
- Risk: exact numeric values, dates, اور specific details summarization میں گم ہو سکتے ہیں

## 5.8 /memory Command

/memory sessions memory manage لیے built-in command:

- محفوظ کیے جا سکیں context اور notes, preferences, تاکہ file editing CLAUDE.md
- Information sessions اور load پر خود بخود startup کے پار برقرار رہتی ہیں
- Project conventions, user preferences, frequently used commands, اور current work context محفوظ کر کے لیے مفید
- دوبارہ سمجھانے کا متبادل instructions میں وہی session رہے

## 5.9 Claude Code CLI for CI/CD

-p (یا --print) flag:

```
claude -p "Analyze this pull request for security issues"
```

- Non-interactive mode: prompt process کرنا، اور print پر stdout، exit کرنا،
- User input کا انتظار نہیں کرتا
- CI/CD pipelines میں Claude کا واحد درست طریقہ

CI کے لیے structured output:

```
claude -p "Review this PR" --output-format json --json-schema
'{"type":"object",...}'
```

- `--output-format json` — output کو JSON میں دیتا ہے
- `--json-schema` — output کو schema کے مطابق validate کرتا ہے
- Result کو automatically inline PR comments میں لے کر پوسٹ کر دیتا ہے

**Session context isolation:** Claude session میں جس code generate کیا گیا ہے، اکثر review میں کمی ہوتی ہے، چونکہ review کے وقت challenge ساتھ رکھتا ہے اور اپنی reasoning context (model کی ہوتی ہے) استعمال کرتا ہے۔ Review کے لیے independent instance استعمال کریں۔

**Duplicate comments** review results context کے وقت، پچھلے review کے بعد دوبارہ commits سے بچاؤ: unresolved issues report کی ہدایت دیں یا Claude میں شامل کریں اور

## 5.10 Session Management اور `fork_session`

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- saved context کے ساتھ conversation جاری رکھتا ہے
- Long investigations کے لیے مفید sessions جو متعدد پر پھیلی ہوئی ہیں
- Risk: tool results stale ہو سکتے ہیں یا tool results بدل چکی ہوں تو files کے بعد session اگر پچھلی

`fork_session` shared context سے independent branch بناتا ہے:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتا ہے کہ context inherit تک forks branch point دونوں
- کرتا ہے کہ diverge اس کے بعد وہ آزادانہ طور پر
- Approaches compare یا strategies test کرنے کے لیے مفید

**Resume** نئی session کے بجائے نئی

- Tool results stale ہوں (files بدل چکی ہوں)
- ہو گیا کہ context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م نہ جو پایا اس کا مختصر خلاصہ" یا "resume کے ساتھ tool data پرانے" یا "restart ..."

# باب 6: Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

## 6.1 Few-shot Prompting

Few-shot prompting میں input/output prompt 2–4 دکھانے کے لیے expected behavior کے طریقے جس میں شامل کیے جاتے ہیں examples

**Few-shot text descriptions** زیادہ مؤثر کیوں

- "وہ" کو کئی طریقوں سے سمجھا جا سکتا ہے precise جیسے "زیادہ" instruction میں
- Example decision logic اور expected format غیر میں طور پر
- Model pattern (صرف examples) کرنا generalize پر cases کو نئے

**Few-shot examples** کی اقسام اور استعمال

1. Ambiguous scenarios کے لیے examples:

```
Request: "My order is broken"
Action: Call get_customer -> lookup_order -> check status.
Rationale: "broken" damaged item کو آپ ہو سکتا ہے؛ order details میں درکار
```

```
Request: "Get me a manager"
Action: escalate_to_human call کریں فوراً
Rationale: Customer مانگ رہا ہے خود حل کرنے کی کوشش نہ کریں human واضح طور پر
```

2. Output formatting کے لیے examples:

```
Finding example:
{
  "location": "src/auth/login.ts:42",
  "issue": "SQL injection in the username parameter",
  "severity": "critical",
  "suggested_fix": "Use a parameterized query"
}
```

3. Acceptable problematic code کے لیے examples:

```
// Acceptable (flag نہ کریں):
const items = data.filter(x => x.active);

// Problem (flag کریں):
const items = data.filter(x => x.active == true); // Use strict equality ===
```

4. Different document formats سے extraction کے examples:

Document with inline citations:

"As shown in the study (Smith, 2023), the rate is 42%."

-> {"value": "42%", "source": "Smith, 2023", "type": "inline\_citation"}

Document with bibliography references:

"The rate is 42%. [1]"

-> {"value": "42%", "source": "reference\_1", "type": "bibliography"}

## 5. Informal measurements کے لیے examples:

Text: "about two handfuls of rice"

-> {"amount": "~100g", "original\_text": "two handfuls", "precision": "approximate"}

Text: "a pinch of salt"

-> {"amount": "~1g", "original\_text": "a pinch", "precision": "approximate"}

Few-shot purely rule-based instructions میں مؤثر کے جو non-standard measurement units اور informal خاص طور پر instructions کے لیے بہت متنوع ہوتی ہیں

**Prompts استعمال strict JSON schemas کے لیے structured output جب format normalization rules میں:** شامل کریں normalization rules میں prompt کریں

Normalization:

- Dates: ISO 8601 (YYYY-MM-DD); "yesterday" -> absolute date compute کریں ہمیشہ
- Currency: numeric amount + currency code; "five bucks" -> {"amount": 5, "currency": "USD"}
- Percentages: decimal fraction; "half" -> 0.5

وہ values inconsistent درست و مگر JSON syntactically کم ہوتے ہیں جہاں semantic errors اس سے

## 6.2 Explicit Criteria بمقابلہ Vague Instructions

**Bad (vague):**

Code comments کی accuracy چیک کریں

Conservative high-confidence findings report کریں - صرف

**Good (explicit criteria):**

Comment کو problematic میں اُس صورت میں flag کریں جب:

1. Comment کا actual code behavior سے CONTRADICT کرتا ہو
2. Comment کا حوالہ دہ variable یا function کسی غیر موجود
3. TODO/FIXME comment ایسے bug جو کسی

Flag نہ کریں:

- کہ لحاظ سے پرانہ ہوں style جو صرف comments ایسے
- wording inaccuracies معمولی
- Missing comments (الگ category یہ)

Severity criteria examples کے ساتھ define کے:

CRITICAL: User کہ لیے runtime failure  
Example: Payment process وقت NullPointerException

HIGH: Security vulnerability  
Example: SQL injection, XSS, missing authorization checks

MEDIUM: Logic bug کہ بغیر فوری impact کہ  
Example: Wrong sorting, off-by-one error

LOW: Code quality  
Example: Duplication, کہ لیے data چھوٹہ suboptimal algorithm

## 6.3 Prompt Chaining

Prompt chaining میں توڑنا sequence کی focused steps کو ایک complex task

Step 1: auth.ts analyze کریں (صرف local issues)  
-> Output: auth.ts میں issues کی list

Step 2: database.ts analyze کریں (صرف local issues)  
-> Output: database.ts میں issues کی list

Step 3: Integration pass (cross-file dependencies)  
-> Output: module boundaries پر issues

یہ کیوں اہم:

- **Attention dilution** — جب files دیکھتا تو کچھ files ایک ساتھ ہوت سی model سد بچاتا — جب shallow commentary کر سکتا اور باقی پر
- یقینی بناتا کہ consistent analysis quality کہ لیے file
- Cross-file interactions الگ analysis کہ لیے الگ

Prompt chaining کب استعمال کریں dynamic decomposition بمقابلہ:

- **Prompt chaining** — predictable, repeatable tasks (code review, file migrations)
- **Dynamic decomposition** — open-ended investigations ان subtasks execution وتہ واضح کہ دوران واضح کہ

## 6.4 “Interview” Pattern

Solution implement Claude clarifying questions کہ پوچھتا کہ سد پلا:

Claude: "API کہ لیے caching implement چند سوالات  
1. پسند کرتہ ہیں؟ cache invalidation strategy میں سد کون سی event-based یا TTL آپ  
2. قابل قبول ہ؟ stale data ہو تو کیا cache unavailable اگر  
3. Caching per-user یا global؟ مونی چاہیہ  
4. Cache کہ لیے expected data volume کہ کرنے

یہ کب مفید:

- Unfamiliar domain (fintech, healthcare, legal systems)
- Implications and tasks (cache strategies, failure modes)
- Viable approaches contextually, but selection is challenging

## 6.5 Validation اور Retry-with-Feedback

جب extracted data validation fail کرے:

```
Step 1: Document سے data extract کریں
Step 2: Validate کریں (Pydantic, JSON Schema, business rules)
Step 3: retry کریں کہ ساتھ context ہو – error اگر:
- Original document
- Previous (incorrect) extraction
- Specific error: "Field 'total' = 150, but sum(line_items) = 145. Re-check values."
```

**Retry مؤثر ہوگا:**

- Format errors (date غلط format میں)
- Structural errors (field غلط جگہ)
- Arithmetic inconsistencies (model check دوبارہ کر سکتا ہے)

**Retry مدد نہیں کرے گا:**

- Information source document ہی نہیں ہے
- Required context external ہے (data کسی اور document میں کیا گیا)

**Pydantic validation tool:** Pydantic Python library جو schema-based data validation کے لیے استعمال ہوتی ہے۔ امتحان کے لیے اس کے نکات یہ ہیں:

- **Structural validation:** types, requiredness, enum constraints JSON کے بعد code میں جانچا جاتا ہے
- **Semantic validation:** custom validators business logic enforce کرتے ہیں (sum of items equals total! start\_date < end\_date)
- **Validate-retry loops:** Pydantic validation failure پر error message بنا کر Claude کو error context کے ساتھ prompt دوبارہ کریں
- **JSON Schema generation:** Pydantic models سے JSON Schema generate کر سکتے ہیں۔ `tool_use` کے لیے JSON Schema generate کر سکتے ہیں۔ single source of truth ہے، جو ایک فراہم کرتا ہے

## 6.6 Self-correction

Internal contradictions detect کرنے کا pattern:

```
{
  "stated_total": "$150.00",
  "calculated_total": "$145.00",
  "conflict_detected": true,
  "line_items": [
    {"name": "Widget A", "price": 75.00},
    {"name": "Widget B", "price": 70.00}
  ]
}
```

آپ `conflict_detected` دونوں نکالتا ہے — اگر وہ مختلف ہوں تو Model stated value اور computed value کو discrepancy handle کرنے دیتا ہے

## 7 Message Batches API: باب 7

دستاویزات: [Message Batches](#)

### 7.1 Overview

کرنے دیتا ہے batches submit کے requests کے لیے asynchronous processing کو Message Batches API

| Attribute               | Value                                                                    |
|-------------------------|--------------------------------------------------------------------------|
| Savings                 | 50% کے مقابلے میں 50 synchronous calls                                   |
| Processing window       | 24 hours (latency SLA guarantee) زیادہ سے زیادہ                          |
| Multi-turn tool calling | Supported نہیں (یک request = ایک response)                               |
| Correlation             | request اور response کے لیے <code>custom_id</code> field کو جوڑنے کے لیے |

### 7.2 Batch API کے مقابلے Synchronous API میں استعمال کریں

| Task                          | API         | Why                                                 |
|-------------------------------|-------------|-----------------------------------------------------|
| Pre-merge PR check            | Synchronous | Developer 24 hours انتظار کر رہا ہے؛ قابل قبول نہیں |
| Overnight tech-debt report    | Batch       | savings % صبح تک چاہیے؛ Result 50                   |
| Weekly security audit         | Batch       | savings % فوری نہیں؛ 50                             |
| Interactive code review       | Synchronous | درکار کے response فوری                              |
| 10,000 documents process کرنا | Batch       | Bulk processing؛ savings میں                        |

## 7.3 custom\_id کا استعمال

```
{
  "custom_id": "doc-invoice-2024-001",
  "params": {
    "model": "claude-sonnet-4-6",
    "max_tokens": 1024,
    "messages": [{"role": "user", "content": "Extract data from: ..."}]
  }
}
```

custom\_id آپ کو یہ کرنے دیتا ہے:

- Result کو original document link سے
- Failure submit دوبارہ کی صورت میں صرف
- Successful documents process کو دوبارہ

## 7.4 Batch کو Failures میں Handle کرنا

1. 100 documents کا batch submit کریں
2. 95 succeed 5 fail (context limit exceeded) ہوں
3. Failures کو custom\_id سے identify کریں
4. Strategy (میں تقسیم کریں chunks کو long documents مثلاً) بدلیں
5. 5 failed documents submit کو دوبارہ صرف اُن

## 7.5 SLA Planning

تک لگ سکتا ہے 24 hours کو Batch API چاہے اور result میں hours اگر آپ کو 30

- Submission window: 30 - 24 = **6 hours**
- Batches کو deadline 24 hours سے کم از کم
- Frequent submissions 4 hour windows میں تقسیم کریں

# 8: Task Decomposition Strategies

## 8.1 Fixed Pipelines (Prompt Chaining)

ہوتا ہے defined step سے:

Document -> Metadata extraction -> Data extraction -> Validation -> Enrichment -> Final output

کب استعمال کریں:

- Task structure predictable (reviews میں ایک template follow کریں)
- پہلے سے معلوم ہونے والے steps تمام
- چاہئے کہ reproducibility اور stability آپ کو

## 8.2 Dynamic Adaptive Decomposition

Subtasks intermediate results پر generate ہوتے ہیں:

1. "Legacy codebase میں tests add کریں"
2. -> Glob, Grep (structure map کریں)
3. -> 3 modules بغیر partial coverage کے
4. -> Prioritize: payments module شروع کریں (high risk)
5. -> دریافت ہوئی dependency پر external API: کام کے دوران
6. -> Adapt: tests میں mock add کریں کہ external API لکھنے سے پہلے

کب استعمال کریں:

- Open-ended investigative tasks
- شروع میں معلوم نہ ہونے والے scope جب مکمل
- پر منحصر ہونے والے results کہ step پچھلے step جب ر

## 8.3 Multi-pass Code Review

10+ files والی pull requests کے لیے:

```
Pass 1 (per-file): auth.ts analyze کریں -> local issues کی list
Pass 1 (per-file): database.ts analyze کریں -> local issues کی list
Pass 1 (per-file): routes.ts analyze کریں -> local issues کی list
...
Pass 2 (integration): files درمیان کہ relationships analyze کریں
-> Cross-file issues: inconsistent types, circular dependencies
```

14 files کی pass پر ایک کی خراب:

- Attention dilution: shallow کچھ کی، deep analysis کی files کچھ
- Inconsistent comments: approve دوسری میں، pattern flag میں ایک file
- Missed bugs: cognitive overload واضح ہونے والے errors کی وجہ سے

## 9 Escalation اور Human-in-the-Loop: باب 9

### 9.1 Escalate کی طرف Human کب

Escalation triggers (rules واضح):

| Situation | Action |
|-----------|--------|
|-----------|--------|

|                                                 |                                                                     |
|-------------------------------------------------|---------------------------------------------------------------------|
| Customer "get me a manager" واضح طور پر کہتا ہے | کریں؛ حل کرنے کی کوشش نہ کریں escalate فوراً                        |
| Policy request کو cover نہ کرتی ہو              | Escalate policy جب competitor price matching مثلاً کریں (ہو)        |
| Agent پیش رفت نہ کر سکا                         | کریں escalate کے بعد attempts مناسب تعداد میں                       |
| Threshold financial operation سے اوپر           | Escalate کے ذریعے prompt enforce، کے ذریعے hook ترجیحاً کریں (نہیں) |
| Customer multiple matches تلاش کرتے وقت         | مانگیں؛ انداز نہ لگائیں identifiers مزید                            |

نہیں ہیں reliable trigger جو:

| Unreliable method                  | Why it fails                                            |
|------------------------------------|---------------------------------------------------------|
| Sentiment analysis                 | نہیں کرتا correlate سے Customer کا mood case complexity |
| Model self-rated confidence (1–10) | کمزور ہیں calibration غلط ہو سکتا ہے؛ Model confidently |
| Automatic classifier               | موجود نہ ہو training data؛ ممکن Overengineering         |

## 9.2 Escalation Patterns

Immediate escalation:

Customer: "I want to speak to a manager"  
 Agent: [کرتا ہو escalate\_to\_human call فوراً]  
 NOT: "I can help with your issue, let me..."

Resolve escalation: کی کوشش کے بعد

Customer: "My refrigerator broke two days after purchase"  
 Agent: [کرتا ہو warranty replacement offer، چیک کرتا ہو]  
 escalate -> مطمئن نہ ہو customer اگر

Nuanced escalation (acknowledge → resolve → reiteration پر escalate):

Customer: "This is outrageous, I'm very unhappy with the quality!"  
 Agent: [frustration acknowledge] "سمجھتا ہوں frustration میں آپ کی"  
 [resolution offer] "replacement یا refund ہو سکتا ہے"  
 Customer: "No, I want to talk to someone!"  
 Agent: [customer insist دوبارہ -> immediate escalation]

کریں escalate دیں، اور صرف اسی وقت concrete solution کریں، پھر emotion acknowledge بنیادی اصول: پہلا  
 manager (نہیں) کریں escalate کے پہلا اظہار پر dissatisfaction کی خواہش دہرائیں customer human جب  
 (مانگندہ کے برابر نہیں ہیں)

Policy gap کے لیے escalation:

Customer: "Competitor X has this item 30% cheaper—give me a discount"  
Policy: کرتی ہے price adjustments cover پر site صرف اپنی  
Agent: [escalate – policy competitor price matching کو cover نہیں کرتی]

## 9.3 Structured Handoff Protocols

Escalation کو دینی چاہیے structured summary human agent پر:

```
{
  "customer_id": "CUST-12345",
  "customer_name": "Ivan Petrov",
  "issue_summary": "Refund request for a damaged item",
  "order_id": "ORD-67890",
  "root_cause": "Item arrived damaged; photos attached",
  "actions_taken": [
    "Verified customer via get_customer",
    "Confirmed order via lookup_order",
    "Offered a standard replacement – customer insists on a refund"
  ],
  "refund_amount": "$89.99",
  "recommended_action": "Approve a full refund",
  "escalation_reason": "Customer requested to speak with a manager"
}
```

Human operator کو full conversation transcript صرف یہ — وں کو summary تک رسائی نہیں دینی چاہیے self-contained اس لیے یہ مکمل اور

## 9.4 Confidence Calibration اور Human Oversight

Data extraction systems کے لیے:

1. **Field-level confidence scores:** model کے لیے extracted field کا confidence score نکالتا ہے
2. **Calibration:** labeled validation sets کے thresholds tune کریں استعمال کر کے
3. **Routing:**
  - High confidence + stable accuracy -> automated processing
  - Low confidence یا ambiguous sources -> human review

**Stratified random sampling:**

- High-confidence extractions کا sample audit بھی باقاعدگی سے کریں
- Aggregate 97% accuracy کا document type 40% errors کا چھپا سکتی ہے
- Accuracy کا analyze کے حساب سے field اور document type، میں overall کو صرف

# Multi-agent Systems میں Error Handling: باب 10

## 10.1 Error Categories

| Category   | Examples                                     | Retryable           | Agent action                           |
|------------|----------------------------------------------|---------------------|----------------------------------------|
| Transient  | Timeout, 503, network failure                | Yes                 | Exponential backoff ساتھ retry کریں    |
| Validation | Invalid input format, missing required field | No (input fix کریں) | Request modify اور retry کریں          |
| Business   | Policy violation, threshold exceeded         | No                  | پیش alternative کو سمجھائیں؛ User کریں |
| Permission | Access denied                                | No                  | Escalate کریں                          |

## 10.2 Error-handling Anti-patterns

| Anti-pattern                                | Problem                                                 | Correct approach                                           |
|---------------------------------------------|---------------------------------------------------------|------------------------------------------------------------|
| Generic status “search unavailable”         | Coordinator decide نہیں کر سکتا کہ recover کیسے کرنا ہے | Error type, query, partial results, alternatives واپس کریں |
| Silent suppression (empty result = success) | Coordinator match سمجھتا ہے کہ failure ملا، حالانکہ     | “no results” اور “search failure” میں فرق کریں             |
| Workflow پر پورا failure ایک abort کرنا     | ضائع ہو جاتا ہے partial results تمام                    | Partial results ساتھ جاری رکھیں؛ gaps annotate کریں        |
| Subagent میں infinite retries               | Latency اور resources کا ضیاع                           | Local recovery (1–2 retries)، پھر coordinator تک propagate |

## 10.3 Structured Subagent Error

```
{
  "status": "partial_failure",
  "failure_type": "timeout",
  "attempted_query": "AI impact on music industry 2024",
  "partial_results": [
    {"title": "AI Music Generation Report", "url": "...", "relevance": 0.8}
  ],
  "alternative_approaches": [
    "Try a narrower query: 'AI music composition tools'",
    "Use an alternative data source"
  ],
  "coverage_impact": "Not covered: AI impact on music production"
}
```

کو فیصلہ کرنا کہ آیا ضروری معلومات دیتا ہے coordinator

- Modified query ساتھ retry کریں؟
- Partial results استعمال کریں؟
- subagent کو delegate کسی اور کریں؟
- gap annotate کریں؟ بغیر جاری رکھیں اور section اس

## 10.4 Final Synthesis میں Coverage Annotations

**## Report: AI Impact on Creative Industries**

**### Visual Art (FULL COVERAGE)**

[research results]

**### Music (PARTIAL COVERAGE – search agent timeout)**

[partial results]

⚠️ Note: coverage search agent timeout کی وجہ سے محدود ہے اس section کی

**### Literature (FULL COVERAGE)**

[research results]

# Context میں Production Systems: باب 11

## Management

### کریں Extract میں Separate Block کو Facts 11.1

Conversations history کو (جو summarize کے دوران summarize ہو جاتی ہے) key facts کو extract میں structured block میں:

```
=== CASE FACTS (کیا جائے update آئے fact جب بھی نیا) ===
Customer ID: CUST-12345
Order ID: ORD-67890
Order Date: 2025-01-15
Order Amount: $89.99
Issue: Damaged item on delivery
Customer Request: Full refund
Status: Pending manager approval
===
```

کیوں نہ ہو summarize کتنی ہی history میں شامل کریں، چاہے prompt میں block نہ ہو

### کریں Trimming کو Tool Results 11.2

اگر `lookup_order` 40+ fields مگر current task میں 5 درکار ہیں واپس کرتا ہے

```
# PostToolUse hook: صرف relevant fields رکھیں
@hook("PostToolUse", tool="lookup_order")
def trim_order_fields(result):
    return {
        "order_id": result["order_id"],
        "status": result["status"],
        "total": result["total"],
        "items": result["items"],
        "return_eligible": result["return_eligible"]
    }
```

کم ہوتی ہے noise بچتا ہے اور context اس سے

### Position-aware Input 11.3

Lost-in-the-middle effect کو critical information کو ذہن میں رکھتے ہوئے

[KEY FINDINGS – اوپر]

3 critical vulnerabilities ملیں...

[DETAILED RESULTS – درمیان]

=== File auth.ts ===

...

=== File database.ts ===

...

[ACTION ITEMS – آخر میں]

Priority: merge auth.ts vulnerabilities fix کریں.

## 11.4 Scratchpad Files

Long investigations میں agent key findings scratchpad file میں لکھ سکتا ہے:

```
# investigation-scratchpad.md
## Key findings
- PaymentProcessor in src/payments/processor.ts inherits from BaseProcessor
- refund() تین places میں call ہوئی: OrderController, AdminPanel, CronJob
- External PaymentGateway API limit: 100 req/min
- Migration #47 میں refund_reason (NOT NULL) add کیا - 01-12-2024
```

scratchpad دوبارہ چلانے کے بجائے agent discovery (میں session یا نئی) کو جائے context degrade جب consult کر سکتا ہے

## 11.5 Context Subagents کو Delegate کرنا

```
Main agent: "payments module کی dependencies investigate کریں"
-> Subagent (Explore): 15 files read کرتا، imports trace کرتا
-> Returns: "Payments depends on AuthService, OrderModel, and the external PaymentGateway API"
```

Main agent: context 15 میں files ایک بجائے line کہ رکھتا ہے

**Separate context layer:** Multi-agent systems میں subagent context budget — میں کام کرتا ہے — separate context layer ایک Coordinator ملتی ہے information کے لیے ضروری task اسے صرف اپنے کے طور پر separate context layer میں allocate کرتا ہے، اور global state store، کرتا ہے subagent outputs aggregate کرتا ہے: وہ اسے بھر دیتا ہے جو information کو ایسی agent window نہیں ہوتا، جہاں ایک "context leakage" ہے اس سے دوسروں کے لیے غیر متعلق ہے

**Subagents کے constrained context budgets:**

- Minimal context: specific task + ضروری data
- Subagent کو raw data dumps کے بجائے structured results کی ہدایت دینے کے لیے
- اور کم distractions کا مطلب کم tools کریں — کم limit کو toolset کے subagent سے allowedTools context cost

## 11.6 Structured State Persistence (crash recovery لی کرنا)

کرنا export پر ایک location ایک معلوم state اپنی agent ر:

```
// agent-state/web-search-agent.json
{
  "status": "completed",
  "queries_executed": ["AI music 2024", "AI music composition"],
  "results_count": 12,
  "key_findings": [...],
  "coverage": ["music composition", "music production"],
  "gaps": ["music distribution", "music licensing"]
}
```

Coordinator resume پر ایک manifest load کرنا:

```
// agent-state/manifest.json
{
  "web-search": "completed",
  "doc-analysis": "in_progress",
  "synthesis": "not_started"
}
```

## 12 کو محفوظ رکھنا Provenance: باب 12

### 12.1 Attribution Loss Problem

گم ہو سکتا ہے link "claim → source" کی جاتی ہیں، تو results summarize سے sources جب متعدد

Bad: "The AI music market is estimated at \$3.2B." (No source, no year.)

Good:

```
{
  "claim": "The AI music market is estimated at $3.2B.",
  "source_url": "https://example.com/report",
  "source_name": "Global AI Music Report 2024",
  "publication_date": "2024-06-15",
  "confidence": 0.9
}
```

### 12.2 Conflicting Data کو Handle کرنا

دیں values مختلف sources جب دو

```
{
  "claim": "Share of AI-generated music on streaming platforms",
  "values": [
    {
      "value": "12%",
      "source": "Spotify Annual Report 2024",
      "date": "2024-03",
      "methodology": "Automated classification"
    },
    {
      "value": "8%",
      "source": "Music Industry Association Survey",
      "date": "2024-07",
      "methodology": "Survey of 500 labels"
    }
  ],
  "conflict_detected": true,
  "possible_explanation": "Methodology اور time period فرق کا"
}
```

کو coordinator کے ساتھ محفوظ رکھیں اور attribution کو اندھا دھند منتخب نہ کریں۔ دونوں کو value کسی ایک فیصلہ کرنے دیں۔

## 12.3 Correct Interpretation کے لیے Dates شامل کریں

سمجھ لیا جا سکتا ہے contradiction کو temporal differences کے بغیر Dates:

Bad: "Source A says 10%, source B says 15%. Contradiction."

Good: "Source A (2023) says 10%, source B (2024) says 15%. Likely 5+ سال میں 1% growth."

## 12.4 Content Type کے مطابق Render کریں

میں نہ ٹھونسیں format کے چیز کو ایک کی:

- Financial data -> tables
- News اور analysis -> prose
- Technical findings -> structured lists
- Time series -> chronological ordering

## باب 13: Claude Code کے Built-in Tools

### 13.1 Tool Selection Reference

| Task                              | Tool         | Example                                                          |
|-----------------------------------|--------------|------------------------------------------------------------------|
| تلاش کرنا files کے نام/pattern    | <b>Glob</b>  | <code>**/*.test.tsx</code> , <code>src/components/**/*.ts</code> |
| File contents کے اندر search کرنا | <b>Grep</b>  | Function name, error message, import                             |
| File مکمل پڑھنا                   | <b>Read</b>  | Analysis کے لیے file load کرنا                                   |
| بنانا file نیا                    | <b>Write</b> | Scratch کے file create کرنا                                      |
| precise edit میں file موجود       | <b>Edit</b>  | Unique text match کے ذریعے specific snippet replace کرنا         |
| چلانا Shell command               | <b>Bash</b>  | git, npm, tests, build                                           |

### 13.2 Incremental Investigation Strategy

نہ: پڑھیں کے سمجھ بوجھ کو رفتہ رفتہ بنائیں files ایک ساتھ تمام

1. Grep: entry points تلاش کریں (function definition, export)
2. Read: پڑھیں files ملنے والی
3. Grep: usages تلاش کریں (import, calls)
4. Read: consumer files پڑھیں
5. کریں repeat نہ مل جائے picture جب تک مکمل

### 13.3 Fallback: Edit کے بجائے Read + Write

و: جائے fail کی وجہ سے Edit non-unique text match جب

1. Read — لوڈ کریں file content مکمل
2. Content کو programmatically modify کریں
3. Write — لکھ دیں updated version

## امتحانی ڈومین نوٹس: II حصہ

# 1 Agent Architecture اور Orchestration ڈومین 1 (27%)

## 1.1 Autonomous Task Execution لی آگنٹک لوپس ڈیزائن کرنا

### Key knowledge:

- Agent loop lifecycle: Claude request بھیجیں، `stop_reason` ("tool\_use" بمقابلہ "end\_turn") چیک واپس کریں results کے لیے iteration کریں، اگلی tools execute کریں
- Tool results conversation history میں append تاکہ آپس میں model آگلا action کر سکے
- Model-driven decision making (Claude آگلا tool چنتا) بمقابلہ hard-coded decision trees

### Key skills:

- Flow control: جب `stop_reason = "tool_use"` تو loop جاری رکھیں اور `"end_turn"` پر رک جائیں
- Iterations درمیان context کو tool results میں append کرنا
- Anti-patterns سے بچنا: completion کے لیے assistant text parse کرنا، primary stopping mechanism کے استعمال پر arbitrary iteration limits

## 1.2 Multi-agent Systems (Coordinator–Subagent) Orchestrate کرنا

### Key knowledge:

- Hub-and-spoke architecture: coordinator تمام inter-agent communication، error handling، اور routing کا مالک ہوتا ہے
- Subagents isolated context میں کام کرتے ہیں — وہ خود بخود coordinator کی history inherit نہیں کرتے
- Coordinator responsibilities: task decomposition، delegation، result aggregation، dynamic selection of subagents
- Coordinator کی overly narrow decomposition کا خطرہ

### Key skills:

- Research coverage کم ہے duplication کے درمیان تقسیم کریں تاکہ subagents کو
- Iterative refinement loops implement کریں (coordinator synthesis evaluate اور tasks re-route کریں)
- Observability کے ذریعے route کے coordinator communication کے لیے تمام

## 1.3 Subagent Calls, Context Passing, اور Spawning Configure کرنا

### Key knowledge:

- `Task` tool subagents spawn؛ `allowedTools` میں `"Task"` شامل ہونا چاہیے؛ `coordinator` کو `Task` tool subagents spawn؛
- Subagent context prompt میں `explicitly`؛ `Subagent context prompt` میں `explicitly`؛ `Subagent context prompt` میں `explicitly`؛
- `AgentDefinition` configuration: descriptions, system prompts, tool constraints
- Alternatives explore `fork_session`؛ `session management`؛ `fork_session`؛ `session management`؛

### Key skills:

- Previous agents کو full outputs subagent prompt میں شامل کریں
- Context pass کو `structured formats`؛ `structured formats`؛ `structured formats`؛
- `Task` calls؛ `parallel subagents spawn`؛ `parallel subagents spawn`؛
- Coordinator prompts goals اور quality criteria؛ `step-by-step instructions`؛ `step-by-step instructions`؛

## 1.4 Enforcement اور Handoff Patterns ساتھ Multi-step Workflows Implement کرنا

### Key knowledge:

- Workflow ordering؛ `programmatic enforcement` (hooks, preconditions) اور `prompt guidance`؛ `programmatic enforcement` (hooks, preconditions) اور `prompt guidance`؛
- `deterministic guarantees`؛ `identity verification`؛ `identity verification`؛
- Escalation؛ `structured handoff protocols` (customer ID, reason, recommended action)؛ `structured handoff protocols` (customer ID, reason, recommended action)؛

### Key skills:

- `programmatic preconditions`؛ `downstream calls`؛ `block`؛ `block`؛
- Multi-aspect customer requests؛ `items`؛ `items`؛
- Human کو escalate؛ `structured summaries produce`؛ `structured summaries produce`؛

## 1.5 Tool Calls Intercept اور Data Normalize کرنے کے لیے Agent SDK Hooks

### Key knowledge:

- Hook patterns (مثلاً `PostToolUse`)؛ `tool results`؛ `model`؛ `consume`؛ `consume`؛
- Hooks outgoing calls intercept؛ `compliance rules enforce`؛ `compliance rules enforce`؛
- Hooks `deterministic guarantees`؛ `probabilistic compliance`؛ `probabilistic compliance`؛

## Key skills:

- `PostToolUse` hooks سے data formats normalize کریں (Unix timestamps, ISO 8601, numeric status codes)
- Policy-violating actions block کرنے کے لیے interception hooks اور escalation استعمال کریں اور redirect کریں
- منتخب کریں hooks کے بجائے prompts چاہیے۔ تو تو guaranteed compliance کو business rules جب

## 1.6 Complex Workflows کے لیے Task Decomposition Strategies

### Key knowledge:

- **Fixed pipelines** (prompt chaining) کے مقابلے میں **dynamic adaptive decomposition** کی بنیاد پر intermediate results
- Prompt chaining: sequential steps (پھر integration pass، analyze کو الگ الگ file)
- Adaptive investigation plans جو discovered information کی بنیاد پر subtasks generate کرتے ہیں

### Key skills:

- Predictable multi-aspect reviews کے لیے prompt chaining؛ open-ended investigations کے لیے dynamic decomposition
- Large code reviews کو per-file analysis + separate cross-file integration pass میں تقسیم کریں
- Open-ended tasks کو degrade ہونے سے پہلے prioritized plan کریں، پھر structure map کریں: پھر

## 1.7 Session State, Resuming, اور Forking

### Key knowledge:

- Named sessions continue کرنے کے لیے `--resume <session-name>`
- Shared context سے independent investigation branches بنانے کے لیے `fork_session`
- Resume کی اہمیت agent کو file changes کرتے وقت
- Structured summary کے ساتھ session، stale results کے ساتھ resuming زیادہ reliable سے زیادہ

### Key skills:

- Named investigation sessions continue کرنے کے لیے `--resume` استعمال کریں
- Approaches parallel compare کرنے کے لیے `fork_session` استعمال کریں
- Resuming (context ابھی current ہے) اور نئی session شروع کرنے (results stale ہیں) درمیان انتخاب کریں

## 5.10 fork\_session اور Session Management

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- جاری رکھتا conversation کے ساتھ پچھلی saved context
- پر پھیلی ہوں ان کے لیے مفید sessions جو متعدد Long investigations
- Risk: tool results stale بدل چکی ہوں تو files کے بعد session اگر پچھلی

**fork\_session** shared context سے independent branch بنانا:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتے ہیں context inherit تک forks branch point دونوں
- کرتے ہیں diverge اس کے بعد وہ آزادانہ طور پر
- کرنے کے لیے مفید strategies test کرنے یا Approaches compare

**Resume** نئی session کے بجائے نئی:

- Tool results stale ہوں (files بدل چکی ہوں)
- وہ گیا context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م نہ جو پایا اس کا مختصر خلاصہ یہ ہے": resume کے ساتھ tool data پرانے کیا جائے restart "... سے"

## 2 Tool Design اور MCP Integration (18%) ڈومین

### 2.1 Clear Descriptions کے ساتھ Tool Interfaces Design کرنا

#### Key knowledge:

- Tool descriptions minimal descriptions کرنا؛ LLM tools select میں جن سے mechanism و بنیادی unreliable selection دیتی
- Input formats, example queries, edge cases, اور applicability boundaries کی اہمیت شامل کرنے
- Ambiguous یا overlapping descriptions misrouting کا سبب بنتی ہیں
- System prompt wording tools کے associations کے ساتھ غیر ارادی بنا سکتی ہیں

#### Key skills:

- کریں distinguish سے واضح طور پر similar alternatives کو tool لکھیں جو descriptions ایسی
- Functional overlap کے لیے (مثلاً `analyze_content` -> `extract_web_results`) کریں tools rename ختم کرنے کے لیے
- واضح ہوں input/output contracts میں تقسیم کریں جن کے specialized tools کو General-purpose tools

## 2.2 MCP Tools کے لیے Structured Error Responses Implement کرنا

### Key knowledge:

- MCP tool responses میں `isError` flag
- Transient errors** (timeouts), **validation errors** (bad input), **business errors** (policy violations), اور **access/permission errors** کے درمیان فرق
- Generic errors ("Operation failed") میں recovery decisions روک دینے کے لیے
- Retryable اور non-retryable errors میں فرق

### Key skills:

- `errorCategory` (transient/validation/permission), `isRetryable` اور human-readable message جیسی structured metadata واپس کریں
- Business-rule violations کے ساتھ `retryable: false` کے user-facing explanations کے لیے واضح کریں
- Transient failures کے لیے subagents میں local recovery کے لیے صرف وہ errors propagate کریں جو خود کو حل کر سکیں
- Access failures (retry decision) اور valid empty results (no matches) میں فرق کریں

## 2.3 Agents میں Tools Allocation اور `tool_choice` Configure کرنا

### Key knowledge:

- کم کرتی tool selection reliability (مثلاً 18 کے بجائے 4-5) tools کے زیادہ
- انہیں غلط استعمال کرتے ہیں agents رکھنے والے tools سے specialization
- Scoped tool access: role-relevant tools + cross-role utilities محدود
- `tool_choice: "auto"`, `"any"` اور forced tool selection ( `{"type": "tool", "name": "..."}`  )

### Key skills:

- تک محدود رکھیں relevant tools صرف subagent کا toolset
- General tools کو constrained alternatives کے بدلے (مثلاً `fetch_url` -> `load_document` )
- یقینی اور tool call کے بجائے text answer کے استعمال کریں تاکہ `tool_choice: "any"`
- Specific tool force کے تاکہ execution order assured

## 2.4 MCP Servers اور Agent Workflows میں Claude Code کو Integrate کرنا

### Key knowledge:

- MCP server scope: user کے لیے experiments کے مقابلے ( `.mcp.json` ) project کے لیے ( `~/claude.json` )
- Secrets management کے لیے `.mcp.json` میں environment variable substitution (مثلاً `${GITHUB_TOKEN}` )

- available ہوتا ہے اور جاننے میں اور ایک ساتھ discover پر tools connection کے connected MCP servers تمام ہیں
- MCP resources بطور "content catalogs" (task summaries, database schemas) exploratory tool calls کم کرتے ہیں

### Key skills:

- Shared MCP servers کو project میں `.mcp.json` env-var-based tokens ساتھ configure کے
- Personal/experimental servers کو `~/claude.json` میں رکھیں
- Standard integrations کے لیے community MCP servers کو custom servers پر ترجیح دیں

## 2.5 Built-in Tools (Read, Write, Edit, Bash, Grep, Glob) منتخب اور کرنا Apply

### Key knowledge:

- **Grep**: file contents کے اندر search (function names, error messages, imports)
- **Glob**: name/extension patterns کے تلاش کرنا files کے
- **Read/Write**: full-file operations؛ **Edit**: unique text matches کے ذریعے precise changes
- **Read + Write** پر واپس جائیں تو fail کی وجہ سے کے Edit non-unique matches کے

### Key skills:

- Content search کے لیے Grep اور pattern-based discovery کے لیے
- **Read** کے لیے flows trace پھر، **Grep** کے لیے entry points: سمجھ بوجھ رفتہ رفتہ بنائیں
- Wrapper modules کے ذریعے function usage trace کریں

## 3 اور Claude Code Configuration: ڈومین Workflows (20%)

### 3.1 Hierarchy, Scope, اور Modular Organization کے ساتھ CLAUDE.md Configure کرنا

#### Key knowledge:

- CLAUDE.md hierarchy: user ( `~/claude/CLAUDE.md` ), project ( `.claude/CLAUDE.md` یا root `CLAUDE.md` ), اور directory-level (subdirectories میں `CLAUDE.md`)
- User-level settings اور user صرف ایک ہیں؛ VCS کے ذریعے share کے لیے اور لاگو ہوتے ہیں اور
- External files refer کے لیے `@path` syntax (مثلاً `@./standards/coding-style.md`) تاکہ CLAUDE.md modular بنے
- Monolithic CLAUDE.md بجائے topic-focused rule files کے لیے `.claude/rules/` directory

### Key skills:

- user-level اس لیے میں ملتیں کیونکہ وہ instructions کو team member (نہ) کریں Hierarchy issues diagnose (میں نہ) میں تھیں، project-level
- (مثلاً) @path کرنے کے لیے standards selectively include میں CLAUDE.md کے package کو استعمال کریں ( @./standards/testing.md )
- files (testing.md, api-conventions.md, deployment.md) .claude/rules/ کو متعدد CLAUDE.md بڑے میں تقسیم کریں

## 3.2 Custom Slash Commands اور Skills بنانا اور Configure کرنا

### Key knowledge:

- `~/.claude/commands/` بمقابلہ `(VCS کے ذریعے shared)` **Project commands** میں `~/.claude/commands/` **user commands** میں
- `~/.claude/skills/` میں SKILL.md frontmatter: `context: fork` , `allowed-tools` , `argument-hint`
- `context: fork` skill کو isolated subagent context سے تارک کرتا ہے تاکہ main session pollute نہ ہو
- Personal skill variants `~/.claude/skills/` میں رکھ سکتے ہیں

### Key skills:

- Project slash commands `.claude/commands/` پوری team میں رکھیں تاکہ پوری
- Verbose output `context: fork` استعمال کریں `skills isolate` والے `کے لیے`
- Skill `allowed-tools` محدود کرنے کے لیے `tools` کے استعمال کردہ
- Required parameters `argument-hint` مانگنے کے لیے

### 3.3 Conditional Convention Loading

#### Path-specific Rules

استعمال کرنا

### Key knowledge:

- `.claude/rules/` files میں YAML frontmatter `paths` تاکہ `glob patterns` شامل ہو سکتا ہے۔ `rules activate` ہوں
- `Path-scoped rules` `matching files edit` وقت `load` کریں، `tokens` اور `context`، `بچتے` ہیں
- `Glob-based path rules` `directory-level CLAUDE.md` میں جب `conventions` سے `بتر` ہو سکتے ہیں جب `tests` (مثلاً) `apply` میں `directories`

### Key skills:

- `paths: ["terraform/**/*"]` `.claude/rules/` files پر load matching files تاکہ صرف `files` کے ساتھ `paths` کے مطابق فائلوں کو تلاش کیا جاسکے۔
- Glob patterns ( `**/*.test.tsx` ) تاکہ `location` استعمال کریں تاکہ `file type` کے لحاظ سے `file type` کے مطابق فائلوں کو تلاش کیا جاسکے۔
- `path-specific` کے بجائے `directory-level CLAUDE.md` بھر میں پھیلی ہوئی `conventions codebase` جب کو ترجیح دیں

## 3.4 Planning Mode □ Direct Execution بمقابلہ

### Key knowledge:

- **Planning mode:** complex tasks, □ changes, multiple viable approaches, اور architectural decisions □ □
- **Direct execution:** □ (شامل کرنا single validation مثلاً) changes سادہ, اچھی طرح سمجھ □ گڈ
- Planning mode changes □ □ codebase کی safe exploration □ □ ممکن بنانا
- Explore subagent verbose discovery output isolate □ □ کرنا

### Key skills:

- Architectural consequences □ □ tasks (microservices, 45+ files والی migrations) □ □ planning mode استعمال کریں
- استعمال کریں direct execution □ □ fixes □ □ والی single file اور stack trace واضح
- Multi-phase tasks میں context-window exhaustion □ □ Explore subagent روکنے □ □
- Approaches □ □ execute □ □ plan, implementation □ □ لیکن discovery □ □ کریں کو combine

## 3.5 Progressive Improvement □ Iterative Refinement

### Key knowledge:

- Concrete input/output examples expectations communicate □ □ مؤثر طریقہ □ □ میں
- **Test-driven iteration:** □ □ tests □ □ لکھیں, پھر □ □
- “Interview” pattern: Claude clarifying questions □ □ تاکہ □ □ non-obvious design considerations □ □ سامنے آئیں
- □ □ (independent) کب sequentially اور (interdependent) میں کب دیں message ایک issues تمام

### Key skills:

- Transformation requirements 3–2 □ □ لیکن □ □ concrete input/output examples کریں
- Implementation □ □ □ □ expected behavior, edge cases, اور performance requirements □ □ test sets بنائیں
- Design aspects (cache invalidation, failure modes) □ □ □ □ interview pattern □ □ سامنے لانے □ □
- Edge cases □ □ □ □ sample inputs اور expected outputs □ □ ساتھ

## 3.6 Claude Code کو CI/CD Pipelines میں Integrate کرنا

### Key knowledge:

- Automated pipelines میں non-interactive mode □ □ □ □ (-p یا --print) flag
- CI میں structured output □ □ □ □ (--output-format json) اور □ □ (--json-schema)
- CLAUDE.md project context (testing standards, review criteria) □ □ □ □
- **Session context isolation:** code generate □ □ □ □ same session □ □ review □ □ میں کم مؤثر □ □

## Key skills:

- Interactive input پر hang لے لے کر لیجئے کہ وہ CI میں Claude Code کو -p کے ساتھ چلائیں
- Structured results (مثلاً inline PR comments) کے لیے --output-format json + --json-schema استعمال کریں
- new/unfixed issues (صرف) شامل کریں review results کے وقت پچھلے run کے بعد دوبارہ commits نہ (کریں report)
- Test generation quality کے لیے CLAUSE.md میں testing standards اور available fixtures document کریں
- style نہ ہو اور duplication میں شامل کریں تاکہ context کو existing test files کے وقت tests generate نہ کرے consistent رہے

## 4 Prompt Engineering اور Structured Output (20%)

### 4.1 Accuracy کے Prompts کے ساتھ Explicit Criteria، تر کرنے کے لیے لی کرنا Design

#### Key knowledge:

- Explicit criteria vague instructions میں زیادہ مؤثر ہوتے ہیں (مثلاً "flag comments only when they contradict code" بمقابلہ "check comment accuracy")
- "be more conservative" generic guidance concrete categorical criteria کے مؤثر ہیں
- False positives developer trust پر اثر انداز ہوتے ہیں: کچھ categories میں high false-positive rates درست کم کر دیتی ہیں trust پر بھی categories

#### Key skills:

- Review criteria define کرنا (bugs, security) اور ignore کرنا (minor style) کرنا
- High false-positive rates والی categories طور پر disable عارضی طور پر
- explicit severity criteria define کے ساتھ code examples کے لیے level پر

### 4.2 Output Consistency کے Few-shot Prompting، تر کرنے کے لیے لی کرنا استعمال کرنا

#### Key knowledge:

- Few-shot examples consistently formatted, actionable output مؤثر ہے کہ سب کے سب method پیدا کرنے کا سب سے
- Few-shot cases (tool selection, test coverage gaps) کو دکھا سکتا ہے
- Few-shot model کو نہ generalize پر patterns کو نہ، صرف مدد دیتا ہے،
- Few-shot extraction tasks میں hallucinations کو نہ کر سکتا ہے

## Key skills:

- Ambiguous scenarios کے لیے rationale 4–2 کے ساتھ targeted examples دینے
- Output format (location, issue, severity, suggested fix) کے ساتھ examples دکھانے والے
- میں فرق دکھائیں real issues اور acceptable code patterns دینے جو examples ایسے
- دینے examples کے extraction سے درست documents والے structures مختلف

## 4.3 Structured Output کے ساتھ JSON Schemas اور tool\_use کرنا Enforce

### Key knowledge:

- tool\_use with JSON Schemas schema-conformant output اور JSON syntax errors کی ضمانت دینے کا طریقہ قابل اعتماد کرنا کا سب سے
- tool\_choice: "any" واپس کر سکتا ہے؛ model text میں "any" منتخب کرتی ہے؛ forced selection specific tool؛
- Strict JSON Schemas syntax errors semantic errors ختم کرتی ہیں مگر (توٹاں؛ totals) میں غلط fields (میں غلط values)
- Schema design: required vs optional fields؛ enums کے ساتھ "other" + detail string extensibility کے لیے

### Key skills:

- JSON Schemas کے ساتھ extraction tools define کریں اور tool\_use results سے data parse کریں
- استعمال کریں tool\_choice: "any" یقینی بنانے کے لیے structured output کے ساتھ تو schemas متعدد
- Specific tool call force کریں: tool\_choice: {"type": "tool", "name": "extract\_metadata"}
- Source میں information کی صورت میں values fabricate نہ ہونے کی صورت میں optional/nullable رکھیں
- Extensible categorization کے لیے "unclear" اور "other" enum values + detail fields جیسے استعمال کریں

## 4.4 Extraction Quality کے لیے Validation, Retries, Feedback Loops Implement کرنا

### Key knowledge:

- Retry-with-error-feedback: correction guide کے لیے concrete validation errors میں retry prompt کرنے کے لیے شامل کریں
- فوائد ہونے میں retries کے لیے information source سے تو واپس کرنا
- Feedback loop design: finding کو trigger والا pattern (detected\_pattern) track کریں
- Semantic errors (totals reconcile نہ ہونے کے لیے جو tool\_use سے address ہونے کے لیے)

### Key skills:

- Original document, incorrect extraction, اور specific validation errors کے ساتھ follow-up prompts دینے
- تو اس کی شناخت کریں (میں واپس کرنا external document صرف required info کے لیے) واپس کرنا

- False positives analyze `detected_pattern` fields میں findings کرنے کے لیے
- Discrepancies detect `calculated_total` اور `stated_total` extract کرنے کے لیے self-correction design کریں

## 4.5 Efficient Batch Processing Strategies Design کرنا

### Key knowledge:

- Message Batches API: 50% savings, 24-hour processing window, latency SLA guarantee
- Batch processing non-blocking tasks (overnight reports, audits) اور blocking tasks (pre-merge checks) کے لیے مناسب
- Batch API single request میں multi-turn tool calling support
- `custom_id` fields batch request/response correlate کرتی ہیں

### Key skills:

- Blocking checks synchronous API اور overnight/weekly workloads کے لیے استعمال
- SLA needs مطابق batch submission cadence plan کریں (24-hour guarantee مثلاً 30 processing 4-hour windows کے ساتھ)
- Failed documents (identified by `custom_id`) submit کر کے صرف انہی کو دوبارہ
- Large-scale processing کے ساتھ sample prompts iterate

## 4.6 Multi-instance اور Multi-pass Review Architectures Design کرنا

### Key knowledge:

- Self-review limitations: model reasoning context کو فیصلوں اور اپنے challenge ساتھ رکھتا ہے اور اپنی امکان کم ہوتا ہے
- Independent review instances (generation context بغیر) subtle issues میں بہتر ہوتی ہیں
- Multi-pass review: per-file local analysis + cross-file integration pass attention dilution سے بچانا

### Key skills:

- Changes review second independent Claude instance کے بغیر generation context کرنے کے لیے
- Multi-file reviews کو per-file passes + integration passes میں تقسیم کریں تاکہ cross-file dataflow analysis ہو سکے
- Self-rated confidence کے ساتھ verification passes کے استعمال کو calibrated reviews کو

## 5 Context Management اور Reliability (15%) ڈومین 5

### 5.1 Critical Information Conversation Context محفوظ رکھنا اور Manage کرنا

#### Key knowledge:

- Progressive summarization کے خطرات: numeric values, percentages, اور dates vague summaries میں بدل جاتے ہیں
- Lost-in-the-middle effect: models long inputs کے شروع اور آخر کو زیادہ reliable سے process طریقہ سے کر سکتے ہیں findings miss ہیں، لیکن درمیان کے
- Tool outputs relevance میں context کے مقابلہ میں disproportionately جمع ہو سکتے ہیں (40+ fields جب 5 fields کے درکار ہوں)
- Subsequent API requests میں full conversation history کی اہمیت

#### Key skills:

- Transactional facts کو summarized history سے باہر ایک persistent “case facts” block میں نکالیں
- Verbose tool outputs کو relevant fields تک trim کریں
- Key findings کو aggregated data کے شروع میں explicit section headings رکھیں
- Subagents کے structured outputs میں metadata (dates, sources) شامل کروائیں

### 5.2 Effective Escalation Patterns Design اور Ambiguity Resolve کرنا

#### Key knowledge:

- Suitable escalation triggers: human کی explicit request, policy gaps/exceptions, اور پانا
- Immediate escalation (explicit request) کے اندر attempt-to-resolve (agent scope) کے مقابلہ میں
- Sentiment analysis اور model confidence self-ratings case complexity کے unreliable proxies ہیں
- Multiple customer matches کے heuristic guessing کے بجائے additional identifiers چاہئیں

#### Key skills:

- System prompt میں explicit escalation criteria few-shot examples کے ساتھ دیں
- Human کی explicit request کو بغیر اضافی investigation کے فوراً execute کریں
- Escalate ہو تو silent یا ambiguous کے لیے specific request کسی policy جب
- Tool results میں multiple matches ہوں تو additional identifiers مانگیں

## 5.3 Multi-agent Systems میں Error Propagation Strategies کرنے

### Key knowledge:

- Structured error context (failure type, query, partial results, alternatives) coordinator کو smarter recovery دیتا ہے
- Access failures (timeouts retry decision میں) اور valid empty results (no matches) میں فرق کریں
- Generic error statuses (“search unavailable”) coordinator سے valuable context چھپا دیتا ہے
- Silent suppression یا failure پر پورا workflow abort کرنا anti-patterns میں

### Key skills:

- Structured error context failure type, کیا گیا attempt, partial results, possible alternatives واپس کریں
- Access failures کو valid empty results الگ کریں
- Transient failures subagents کے لیے صرف local recovery میں non-recoverable errors partial results کے ساتھ propagate کریں
- Synthesis میں coverage annotate کیا اچھی طرح supported اور کے ان gaps میں

## 5.4 Large Codebases Investigate کرتے وقت Context Efficiently Manage کرنا

### Key knowledge:

- Long sessions میں context degradation: model unstable answers اور مخصوص classes دینے لگتا ہے
- Scratchpad files key findings کو context boundaries میں پار محفوظ رکھتے ہیں
- Subagents کو delegate سے verbose discovery output isolate ہو جاتی ہے
- Structured state persistence crash recovery ممکن بناتی ہے

### Key skills:

- Specific questions subagents spawn کے لیے high-level coordination main agent میں رکھیں
- Key findings scratchpad files کے لیے refer محفوظ رکھتے ہیں اور بعد میں
- Long investigations کے دوران context usage کے لیے summarize key findings کے لیے phase اگلا
- استعمال کریں `/compact` کم کرنے کے لیے

## 5.5 Human Oversight اور Confidence Calibration کے ساتھ Workflows Design کرنا

### Key knowledge:

- Aggregate metrics (97% overall accuracy) specific document types یا fields پر کمزوری چھپا سکتا ہے
- Stratified random sampling high-confidence extractions میں error rates measure کرنا

- Field-level confidence calibration labeled validation sets ذریعہ
- Automation پُر document type اور field segment حساب سے accuracy validate کریں

### Key skills:

- New error patterns detect کریں stratified random sampling implement کریں
- Stable performance validate کریں accuracy analyze کریں حساب شد اور document type
- Field-level confidence scores output کریں review thresholds calibrate کریں ذریعہ labeled data اور
- Low-confidence یا ambiguous-source extractions human review کریں route کی طرف

## 5.6 Multi-source Synthesis میں Provenance Preserve کرنا اور Uncertainty Handle کرنا

### Key knowledge:

- محفوظ نہ رہیں mappings “claim → source” کہو جاتی ہیں اگر attribution کا دوران Summarization
- برقرار رہتی چاہئیں structured mappings کا دوران Aggregation
- conflict annotate کا ساتھ attribution منتخب کرنے کا بجائے value ایک arbitrarily کو conflicting statistics  
ہیں handle کریں
- publication/collection dates سمجھنے سے بچنے کا لیے contradiction کو Temporal differences شامل کریں

### Key skills:

- Subagents کے “claim → source” mappings (URL، document name، quotes) output کروائیں
- Reports کو stable findings اور disputed ones میں الگ کریں
- Conflicting values کے annotations اور ساتھ محفوظ رکھیں
- Correct temporal interpretation کے لیے reconciliation کے ساتھ
- Correct publication dates کے لیے
- Content type کے مطابق: financial data tables، news prose، technical findings، structured lists میں

# Claude Certified Architect — Foundations Certification

## مطالعہ □ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

## تعارف

Claude Certified Architect — Foundations

Claude- based سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) کے بنیادی ٹیکنالوجیز جن کو جانچنا ہے — امتحان trade-off حل بنانا، وقت درست کر سکتا ہے، یعنی وہ بنیادی ٹیکنالوجیز جن کو جانچنا ہے، کے ساتھ پروڈکشن ایپلیکیشنز تیار کی جاتی ہیں، Claude سے۔

بنانا agentic systems امتحان کے سوالات حقیقی دنیا کے منظر ناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، Claude Code کو CI/CD شامل کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا

## هدف امیدوار

کرتا آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

## امتحانی فارمیٹ

| پیرامیٹر         | قدر                                      |
|------------------|------------------------------------------|
| سوال کی قسم      | Multiple choice (میں سے 1 درست 4)        |
| اسکورنگ          | 100–1000 scale، passing score <b>720</b> |
| Guessing penalty | نہیں (سوال کا جواب دیں!)                 |
| Scenarios        | 8 4 (randomly selected) میں سے           |

## امتحانی مواد: 5 ڈومینز

| ڈومین                                       | وزن        |
|---------------------------------------------|------------|
| 1. Agent architecture and orchestration     | <b>27%</b> |
| 2. Tool design and MCP integration          | <b>18%</b> |
| 3. Claude Code configuration and workflows  | <b>20%</b> |
| 4. Prompt engineering and structured output | <b>20%</b> |
| 5. Context management and reliability       | <b>15%</b> |

# امتحانی منظرنامہ

## Scenario 1: Customer Support Agent

returns, billing disputes, account issues استعمال کرتے ہوئے Claude Agent SDK بناتے ہیں جو agent آپ ایک agent MCP tools (get\_customer, lookup\_order, process\_refund, escalate\_to\_human) سنبھالتا ہے۔ مناسب first-contact resolution % استعمال کرنا 80 دفعہ (escalation) کے ساتھ۔

## Scenario 2: Claude Code ساتھ Code Generation

code generation, refactoring, debugging, documentation آپ کو اسدے custom slash commands اور CLAUDE.md configuration کے استعمال کو سمجھنا planning mode کرنا، اور integrate

## Scenario 3: Multi-Agent Research System

tasks کو coordinator agent specialized subagents: web research, document analysis, synthesis, report generation اور citations سسٹم کو

## Scenario 4: Developer Productivity Tools

routine tasks بنانے، اور boilerplate code explore unfamiliar codebases کو agent engineers یں استعمال MCP servers اور Built-in tools (Read, Write, Bash, Grep, Glob) میں مدد دیتا ہے۔

## Scenario 5: Claude Code for Continuous Integration

pull اور automated code reviews, test generation, CI/CD pipeline کو Claude Code کم سے کم false positives ایسے بننے چاہئیں کہ Prompts حاصل ہو۔

## Scenario 6: Structured Data Extraction

JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے۔ درست طور پر سنبھالنے چاہئیں edge cases برقرار رکھتا ہے۔

## Scenario 7: Conversational AI Architecture Patterns

multi-turn conversational systems میں جن میں context window management، turns متعدد، memory strategies، execution محفوظ، tool design کے لیے، instructions میں اور مہم یا متضاد، user inputs کو سنبھالنا شامل ہے۔

## Scenario 8: Agentic AI Tools (ہماری مدد کریں — مواد موجود نہیں)

میں شامل نہیں دی لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس میں share میں GitHub Issues کے سوالات دیکھیں، تو انہیں scenario اگر آپ نے اصل امتحان میں اس شامل کر سکیں آپ کا تعاون اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ ہم مکمل رہے۔

# نظریاتی بنیادیں: حصہ 1

یہ حصہ و بنیادی نظریہ بیان کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو topic کے مطابق — اس کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts اور technologies کی گہری سمجھ بھنی کے لیے۔

## کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

### 1.1 API Request Structure

Claude API میں عموماً یہ Claude Messages API request پر کام کرتا ہے request-response model ایک request-response model میں شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    { "role": "user", "content": "Hi!" },
    { "role": "assistant", "content": "Hello!" },
    { "role": "user", "content": "How are you?" }
  ],
  "tools": [...],
  "tool_choice": { "type": "auto" }
}
```

م فیلڈز:

- `model` — model selection ( `claude-opus-4-6`, `claude-sonnet-4-6`, `claude-haiku-4-5` )
- `max_tokens` — response میں زیادہ سے زیادہ tokens
- `system` — system prompt (model کی تعریف)
- `messages` — conversation history (full history کے لیے ضروری)
- `tools` — available tools کی definitions
- `tool_choice` — tool selection strategy

### 1.2 Message Roles

roles میں تین array: `messages`

- `user` — user messages
- `assistant` — model responses (history میں شامل ہوتے ہیں)

- `tool` — tool call results (عملاً `tool_result` content block)

محفوظ state کے درمیان Model requests بھیجیں conversation history میں مکمل API request م بات: ر آزاد ہوتی call نہیں رکھتا؛ ر

## 1.3 stop\_reason

نہ کیوں رکا model ہوتا جو بتاتا کہ `stop_reason` میں Claude API response

| Value           | Description               | Action                                  |
|-----------------|---------------------------|-----------------------------------------|
| "end_turn"      | نہ جواب مکمل کر لیا Model | کو نتیجہ دکھائیں user                   |
| "tool_use"      | چاہتا Model tool call     | واپس دیں result چلائیں اور tool         |
| "max_tokens"    | ختم ہو گئی Token limit    | بڑھا سکتے ہیں limit؛ response truncated |
| "stop_sequence" | مل گئی Stop sequence      | کریں handle کے مطابق application logic  |

کرے loop control ہیں — یہی signals سب سے اہم "end\_turn" اور "tool\_use" میں Agentic systems ہیں

## 1.4 System Prompt

متعین کرتا context اور behavioral rules جو instruction ایک خاص System prompt

- `messages` array الگ ہوتا؛ `system` field کا حصہ نہیں ہوتا؛ الگ
- user messages پر فوقیت رکھتا
- ہو کر پوری گفتگو میں لاگو رہتا load ایک بار
- کی وضاحت کے لیے استعمال ہوتا output format اور role, constraints,

کو غیر ارادی طور پر متاثر کر سکتی مثال tool selection wording کی system prompt: امتحان کے لیے اہم ضرورت سے زیادہ `get_customer` کو model کی تصدیق کریں "جیسی ہدایت customer کے طور پر" ہمیشہ استعمال کرنے پر ل جا سکتی

## 1.5 Context Window

کر سکتا اس میں شامل process ایک وقت میں model جس (tokens) و کل متن Context window

- System prompt
- message history مکمل
- Tool definitions
- Tool results

اہم مسائل:

1. **Lost-in-the-middle effect:** درمیان کی input لمبے، مؤثر ہوتی ہیں، آغاز اور اختتام کی معلومات زیادہ مؤثر ہوتی ہیں، حل: اہم معلومات شروع یا آخر میں رکھیں details miss

2. **Tool results** واپس tool 40+ fields شامل کرتی ہیں اگر output میں tool call context کا جمع ہونا: ہر Tool results ضائع ہوتا ہے context کو مگر صرف 5 امیون تو
3. **Progressive summarization:** history compress کرنے پر numeric values, percentages, اور dates اکثر vague ہوتی ہیں

## 2 tool\_use اور Tools: باب 2

Tool Use: دستاویزات

### 2.1 tool\_use کیا ہے

براہ راست Model کو external functions call کرنے کے لیے Claude جس کے ذریعے mechanism tool\_use واپس کرتا ہے result کو execute اس کے لیے code بنانا ہے: آپ کا structured tool call نہیں چلاتا — وہ code درست ہے

### 2.2 Tool Definition

tool JSON schema کے ذریعے define ہوتا ہے:

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

Tool description نکات:

1. Description کا سبب بنتی selection غلط Minimal descriptions mechanism کا بنیادی tool selection ہے
2. Description کا input format، کیا کرتا ہے، کیا واپس کرتا ہے tool میں شامل کریں
3. Overlapping descriptions سے بچیں
4. Built-in tools اور MCP tools overlap کو بتر اور واضح بنائیں MCP tool

## 2.3 tool\_choice

| Value                                                       | Behavior                         | کب استعمال کریں              |
|-------------------------------------------------------------|----------------------------------|------------------------------|
| <code>{ "type": "auto" }</code>                             | Model خود ط کرتا ہے              | default عام                  |
| <code>{ "type": "any" }</code>                              | Model tool call کو لازماً کرے گی | structured output جب چاہے    |
| <code>{ "type": "tool", "name": "extract_metadata" }</code> | Model tool call کو لازماً کرے گی | forced first step / order ہے |

## 2.4 JSON Schemas for Structured Output

reliable لینے کا سب سے structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas کی semantic correctness نافذ کرتا ہے، مگر required structure کم کرتا ہے اور syntax errors طریقہ کے ی ضمانت نہیں دیتا

### Design اصول:

- رکھیں جو ہمیشہ ملنے چاہئیں required fields صرف وہ
- استعمال کریں nullable fields کے لیے missing data ممکن
- ضائع نہ ہو information شامل کریں تاکہ enum values جیسے "unclear" اور "other"

## 2.5 Syntax اور Semantic Errors

| Error type | Example                                 | Mitigation                                |
|------------|-----------------------------------------|-------------------------------------------|
| Syntax     | Invalid JSON, field type غلط            | JSON schema کے ساتھ <code>tool_use</code> |
| Semantic   | Totals match نہیں کرتے، value field غلط | Validation checks, feedback retry         |

# بنانا Claude Agent SDK — Agentic Systems: باب 3

دستاویزات: [Agent SDK](#) | [Hooks](#) | [Subagents](#) | [Sessions](#)

## 3.1 Agentic Loop

چلانا sequence کی actions صرف جواب نہیں دیتا، بلکہ Claude میں Agentic loop

- بھیجیں request کے ساتھ tools کو Claude
- Response لیں
- چیک کریں `stop_reason`:
  - "tool\_use" → tool چلائیں، result history پھر دوبارہ request میں ڈالیں

- "end\_turn" → task کو دین user مکمل، نتیجہ

مکمل ہونے تک دہرائیں۔ 4.

Text parsing یا arbitrary iteration دیکھیں کہ `stop_reason == "end_turn"` کی لیے `signal: completion` درست قابل اعتماد نہیں ہے۔


## 3.2 AgentDefinition

```
agent = AgentDefinition(
    name="customer_support",
    description="Handles customer requests for returns and order issues",
    system_prompt="You are a customer support agent...",
    allowed_tools=["get_customer", "lookup_order", "process_refund",
"escalate_to_human"],
)
```

اصول اپنائیں کہ Least privilege کہ `allowed_tools` اور، `system_prompt`، `description`، `name` م چیزیں

## 3.3 Coordinator اور Subagents

استعمال کرتی ہیں hub-and-spoke topology اکثر Multi-agent systems



Coordinator task کو توڑتا ہے، subagents نتائج جوڑتا ہے، کام سونپتا ہے، منتخب کرتا ہے، errors handle کرتا ہے، جواب پہنچاتا ہے۔ final تک user، اور

نہیں کرتے۔ inherit خود بخود parent history الگ ہوتا ہے؛ وہ context کا subagents

## 3.4 Task Tool

Subagents `Task` tool کے ذریعے spawn کیے جاتے ہیں۔ Coordinator کے `allowed_tools` میں "Task" ہونا چاہیے۔

context passing: صحیح

- Task: "Analyze the document" کافی نہیں
- Task: "Analyze this document. Full text: ... Output schema: ..." درست ہے

ممکن ہیں کہ parallel subagents بھیج سکتا ہے، لہذا Task s multiple میں response ایک Coordinator

## 3.5 Hooks

کرتے ہیں کہ work پر points کے مخصوص lifecycle Hooks

PostToolUse tool result کو model پر لے کر normalize تک پہنچانے سے پہلے:

```
@hook("PostToolUse")
def normalize_dates(tool_result):
    return normalized_result
```

PreToolUse policy violation block کر سکتا ہے:

```
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

Critical business rules کو پوری یقینیگی سے prompt instructions probabilistic کو پوری یقینیگی سے؛ hooks deterministic: یاد رکھیں rules کو لے کر hooks کو پوری یقینیگی سے بہتر یقینیگی سے

## باب 4: Model Context Protocol (MCP)

[MCP](#) | [Tools](#) | [Resources](#) | [Servers](#) : دستاویزات

### 4.1 MCP کیا ہے

MCP resource سے جوڑتا ہے اس کے تین بنیادی Claude کو external systems کو جو open protocol ایک types ہیں:

1. **Tools** — actions کے لیے functions
2. **Resources** — context data (documentation, schemas, catalogs)
3. **Prompts** — predefined task templates

### 4.2 MCP Servers

MCP server ایک process جو tools/resources expose کرتا ہے Connect پر tools discover ہونے پر۔ مطابقت استعمال ہونے والے descriptions ہیں اور

### 4.3 Configuration

Project config ( `.mcp.json` ) لے کر:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {"GITHUB_TOKEN": "${GITHUB_TOKEN}"}
    }
  }
}
```

User config سہ آتی ہے secrets environment variables میں ہوتی ہے؛ Project config version control (~/claude.json) personal/experimental servers کے لیے ہوتی ہے

## 4.4 isError

واپس کریں structured error کے بجائے Generic errors استعمال کریں `isError: true` میں MCP tool errors

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable."
  }
}
```

## 4.5 Resources

Resources کے پڑھ سکتا ہے action بغیر agent میں جو data و schemas, docs, content catalogs, summaries کے exploratory tool calls میں کم کرتے ہیں

# 5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

## 5.1 CLAUDE.md Hierarchy

تین سطحوں پر ہو سکتا ہے CLAUDE.md

- **User-level:** `~/ .claude/CLAUDE.md` — پر لاگو user صرف اسی
- **Project-level:** `.claude/CLAUDE.md` یا `root` `CLAUDE.md` — لی تیم پوری
- **Directory-level:** subdirectories میں `CLAUDE.md` — folder conventions مخصوص

## 5.2 @path Syntax

CLAUDE.md میں @path سے external files refer تاکہ جا سکتے ہیں تاکہ:

Coding standards `@./standards/coding-style.md` میں ہیں  
Test rules `@./standards/testing-requirements.md` میں ہیں

## 5.3 .claude/rules/

`.claude/rules/` rules کو topic سے لحاظ سے organize کرنا اور `paths` کے ذریعے conditional loading کرتا ہے:

```
---
paths: ["src/api/**/*"]
---
```

استعمال کریں explicit error handling اور async/await کہ لہ API files

## 5.4 Commands اور Skills

`.claude/commands/` project commands کے لیے، جبکہ `~/ .claude/commands/` personal commands کے لیے ملتی ہیں۔ skills کے ساتھ `.claude/skills/` کے لیے

## 5.5 Skills اور context: fork

`context: fork` skill کو isolated context میں چلاتا ہے `allowed-tools` اور tool access سے، اور `argument-hint` required input مانگیں

## 5.6 Planning Mode

Planning mode کے لیے، بہترین unfamiliar codebases اور multiple approaches، تبدیلیوں architectural بڑی Direct execution کے لیے، بہتر changes چھوٹے اور واضح

## 5.7 /compact اور /memory

`/compact` context compress کرتا ہے، اور `/memory` notes اور preferences میں مدد دیتا ہے

## 5.8 Claude Code CLI for CI/CD

ک: لے استعمال ہوتا ہے non-interactive mode / -p --print

```
claude -p "Analyze this pull request for security issues"
```

Structured output لے لے --output-format json اور --json-schema استعمال کریں

## باب 6: Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

### 6.1 Few-shot Prompting

Few-shot prompting 4–2 examples میں کر expected behavior لے vague instructions دکھایا جاتا ہے کم کرتا example ambiguity زیادہ مؤثر ہے کیونکہ

### 6.2 Explicit Criteria

Vague instructions بجائے clear criteria دین: کیا flag اور ignore کرنا، severity کرنا، decide کیسے کرنا

### 6.3 Prompt Chaining

Complex task کو focused steps میں توڑیں: local analysis، integration pass، attention dilution کم کرتا

### 6.4 Interview Pattern

Claude clarifying questions design ambiguity پوچھوانا domain سامنے لاتا، خاص طور پر جب unfamiliar ہو

### 6.5 Validation and Retry

Extraction fail ہو تو original document، incorrect output، specific validation error ساتھ retry کرنا

## 6.6 Self-correction

کریں discrepancy handle تو conflict دونوں نکال؛ Model stated value اور calculated value

## 7: Message Batches API

Message Batches: دستاویزات

### 7.1 Overview

Message Batches API asynchronous processing 50: % savings، up to 24 hours window، اور multi-turn tool calling supported، custom\_id requests اور responses link

### 7.2 کب استعمال کریں

Pre-merge checks اور interactive tasks، synchronous API، overnight reports اور bulk jobs، استعمال کریں Batch API

### 7.3 custom\_id

custom\_id result کو original document، جوڑ، failures identify اور صرف، failed items دوبار، submit میں مدد دیتا

## 8: Task Decomposition Strategies

### 8.1 Fixed Pipelines

Predictable tasks، fixed pipeline، Document → Extraction → Validation → Final output

### 8.2 Dynamic Decomposition

Open-ended tasks، subtasks intermediate results، کی بنیاد پر بنتا

### 8.3 Multi-pass Code Review

Large PRs، per-file analysis، cross-file integration pass، attention dilution، کم

## 9 Escalation اور Human-in-the-Loop: باب 9

### 9.1 Escalate کب کریں

Explicit user request, policy gaps, progress نہ ہونا, threshold سے اوپر financial action, یا ambiguous matching میں Sentiment analysis اور self-rated confidence unreliable ہیں۔ Escalate کی صورت میں

### 9.2 Escalation Patterns

human کو hand off نہ کرنا یا explicit insistence یا policy gap نہ کرنے کی کوشش کریں، پھر اگر resolve نہ ہو، مسئلہ حل کریں۔

### 9.3 Structured Handoff

human شامل کریں تاکہ recommended action اور، actions taken, issue summary, customer ID پر Escalation operator کو مکمل context ملے۔

### 9.4 Confidence Calibration

Field-level confidence scores, calibration on labeled data, اور stratified sampling استعمال کریں۔

## 10 Error Handling میں Multi-agent Systems: باب 10

### 10.1 Error Categories

Transient errors retryable ہیں، validation errors input fix ہیں، مانگتی business errors policy-driven ہیں، اور permission errors generally escalate ہیں، اور

### 10.2 Anti-patterns

Generic “search unavailable” response, silent suppression, workflow abort یا پورا کرنا نقصان دہ۔ Structured errors واپس کریں۔

### 10.3 Structured Subagent Error

Structured error میں failure type, attempted query, partial results, alternative approaches, اور coverage شامل کریں۔

## 10.4 Final Synthesis میں Coverage

پارٹیاں، اور کچھ partially covered ہیں، کون سی sections fully covered میں واضح کریں کہ کون سی Report باقی ہیں۔ gaps

# 11 Context میں Production Systems: باب 11 Management

## 11.1 Facts Separate Block میں

Transactional facts کو persistent case facts block تاکہ summarization میں رکھیں تاکہ critical data کے باوجود زچہ و

## 11.2 Tool Results Trimming

PostToolUse hook رکھیں relevant fields سے صرف

## 11.3 Position-aware Input

Important findings اور action items شروع میں اور lost-in-the-middle effect کو آخر میں رکھیں تاکہ

## 11.4 Scratchpad Files

Verbose findings scratchpad تاکہ long investigations میں لکھیں تاکہ context محفوظ رہے

## 11.5 Subagents کو Delegate کرنا

Exploration subagents میں دیں اور main context میں صرف summary رکھیں

## 11.6 Structured State Persistence

ممکن ہے crash recovery تاکہ export میں JSON file یا state manifest اپنی agent کے

# 12 Provenance رکھنا: باب 12 کو محفوظ رکھنا

## 12.1 Attribution Loss

Claim رکھیں confidence اور، publication date، source URL کے ساتھ

## 12.2 Conflicting Data

کریں conflict flag ساتھ محفوظ رکھیں اور attribution دیں تو دونوں کو values مختلف sources اگر

## 12.3 Dates

دیکھیں publication dates سمجھنے کے لیے contradiction کو Temporal differences

## 12.4 Content Type کے مطابق Render

Financial data tables میں، news prose میں، technical findings structured lists اور time series میں، chronological order میں دکھائیں

# 13 Claude Code کے Built-in Tools: باب 13

## 13.1 Tool Selection Reference

| Task                      | Tool  | Example                      |
|---------------------------|-------|------------------------------|
| تلاش کرنا file کے pattern | Glob  | <code>**/*.test.tsx</code>   |
| file contents میں search  | Grep  | function name, error message |
| پڑھنا file                | Read  | analysis کے لیے              |
| بنانا file نیا            | Write | scratch کے                   |
| precise edit              | Edit  | unique text match            |
| shell command             | Bash  | git, npm, tests              |

## 13.2 Incremental Investigation

دیکھیں files consumer، پھر usages، پھر entry points، پڑھیں؛ کے لیے files ایک ساتھ سب

## 13.3 Read + Write Fallback

کریں Write کریں، پھر programmatically کریں، تبدیلی Read کے تو Edit fail اگر

## امتحانی ڈومین نوٹس: II حصہ

## 1 ڈومین: Agent Architecture اور Orchestration (27%)

Agentic loops, coordinator–subagent architecture, Task ذریعہ spawning, hooks, escalation, اور multi-step workflows پر فوکس کریں

## 2 ڈومین: Tool Design اور MCP Integration (18%)

Tool descriptions, tool\_choice, JSON schema output, structured errors, MCP servers, resources, اور built-in tools کے فرق کو سمجھیں

## 3 ڈومین: Claude Code Configuration اور Workflows (20%)

CLAUDE.md hierarchy, .claude/rules/, commands, skills, planning mode, context: fork, اور CI/CD integration

## 4 ڈومین: Prompt Engineering اور Structured Output (20%)

Few-shot prompting, explicit criteria, prompt chaining, validation/retry loops, JSON schema enforcement, اور batch-friendly prompting پر توجہ دیں

## 5 ڈومین: Context Management اور Reliability (15%)

Summarization risks, lost-in-the-middle, trimming tool output, confidence calibration, escalation, اور provenance preservation یاد رکھیں

# Scenario 7: Conversational AI Architecture Patterns

## سوال 61

کرنے کے لیے preview سے پہلے اثرات کا execution میں tool remove\_team\_member صورتحال: آپ کے براہ راست agent سے معلوم ہوتا ہے کہ Production monitoring کے parameter dry\_run: boolean سے bypass کو preview step کو call کے ساتھ dry\_run=false کرتا ہے آپ کو یقینی بنانا ہے کہ user نے explicitly confirm سے preview سے پہلے ایک deletion کیا ہے

کونسی approach سب سے قابل اعتماد

- A) Server-side validation شامل کریں جو dry\_run=false سے 60 allow صرف اسی وقت seconds میں parameters کے ساتھ dry\_run=true call ہوئی ہے
- B) Tool کو configuration layer اور orchestration کی ضرورت کے طور پر confirmation کو user کی approval سے forward calls کو annotated tools کے

- C) Tool description میں instructions اور few-shot examples agent کو شامل کریں جن میں `dry_run=true` کا call کرنا ہمیشہ پورا ہوگا۔
- D) دو tools کو replace کریں: `preview_remove_member` ایک single-use confirmation اور `execute_remove_member` کو واپس کرتا ہوگا؛ token کو bind کرنا، درکار token کو واپس کرنا [درست] کرتا ہے۔

D. **کیوں:** Token-binding approach architectural preview ناممکن ہو جاتا ہے۔ LLM کو preview tool generate کر سکتا ہے۔ جو صرف token و literally execute tool کو — execution approach جو LLM instructions کی پابندی، timing heuristics (A)، orchestration infrastructure (B) پر constraint enforce کرے۔ code level پر انحصار نہ کرے۔

## سوال 62

فیلٹرنگ کے بعد، `search_catalog` tool 12% fail وقت کا آپ کا Production monitoring کا **صورتحال** معلوم ہوتا ہے۔  
 8% network timeouts ہیں جو 4 retry ہیں، اور 4% query syntax errors ہیں۔  
 return ایکساں طریقہ سے error types کامیاب نہیں ہوتے۔ فی الحال دونوں  
 retries ہوتے ہیں۔

کریں گے؟ modify کیسے □ error handling کی tool آپ

- A) System prompt میں few-shot examples demonstrate network errors کریں □ میں فرق کیسے کریں □ syntax errors
- B) uniformly exponential backoff retry logic apply کریں □ errors پر تمام
- C) Tool کو syntax errors کریں؛ □ automatic retry with backoff implement □ network timeouts □ اندر □ parameter validation details [درست] □ ساتھ فوری واپس کریں □
- D) □ ساتھ واپس کریں □ error type details □ boolean flag retryable کو errors تمام

کو tool — abstraction boundary کرنا صحیح retries handle کر لی transient errors پر Tool level پر کیوں C  
 agent کر سکتا ہے بغیر deterministic retry logic implement کرے بارے میں یقینی علم ہے اور error type  
 Uniform backoff (B) syntax errors کرے prompt instructions (A) follow کرے یا (D) interpret flag انحصار کرے و  
 پر وقت ضائع کرتا ہے جو کبھی کامیاب نہیں ہوں گے

### سوال 63

بہت کم risk اور risk tolerance کم ہے "میری user، میں turns کی گفتگو کی Investment strategy: صورتحال  
 "کرنا چاہتا ہوں؟ invest کرنا چاہتا ہوں" اب وہ پوچھتا ہے: "مجھے کس چیز میں returns maximize پھر میں اپنے

سہ priority کی اصل recommendation user سہ بہتر طریقہ سہ یقینی بنانا ک approach کونسا م آنگ؟

- A) پوچھیں کہ کونسی چیز زیادہ اہم ہے [درست] user تضاد کو سامنے لائیں اور
- B) فراہم کریں recommendations کہ لپے الگ الگ scenarios دونوں
- C) کہ ساتھ آگے بڑھیں preference سب سے حال میں بیان کی گئی
- D) تجویز کریں balanced portfolio تضاد کو حل کیے بغیر

مانگنا کی واحد clarification برا راست متضاد ہوں، تو تضاد سامنے لانا اور user preferences کی کیوں: جب A low risk کرنا اور Returns maximize کے اصل ارادہ سے ہم آہنگ ہو۔ user recommendation طریقہ کے بنیادی طور پر ناقابل مطابقت ادا ف میں جن کے لیے انسانی فیصلہ درکار کے tolerance

## سوال 64

jazz کے "مجھے User کرتے ہیں playlist preferences refine میں conversation turns کئی Users: صورتحال "پسند ہیں؟ genres پوچھتا ہے "آپ کو کون سے Claude، بعد messages پسند ہے" کے دو

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) Claude کو conversation memory کے لیے vector database connection برقرار رکھنے کے درکار
- B) Model کی context window exceed ہو گئی
- C) Claude API کو session\_id parameter درکار
- D) شامل نہیں کر رہی [درست] messages میں بچھلے messages array application آپ کی

request کے stateless API call ہیں — server-side memory کے پاس Claude: کیوں D کا کوئی علم turns کے پاس بچھلے Claude، شامل کیے بغیر conversation history میں مکمل messages array کا حصہ نہیں ہیں؛ دو architecture کے Claude (C) session\_id اور (A) Vector databases نہیں ہوتا۔ ناممکن (B) context window overflow کے لیے exchange کے messages

## سوال 65

History تک پہنچ گئی 78,000 tokens conversation، بعد cooking session صورتحال: 40 منٹ کے شامل ہیں آپ کو اسم معلومات discussion اور عمومی، allergies, recipe scaling, clarified cooking terms، کم کرنے ہیں tokens محفوظ رکھتے ہوئے

کے درمیان بہترین توازن رکھتا ہے؟ token reduction اور approach preservation کونسا

- A) خلاصہ کریں conversation history پوری
- B) رکھیں tokens صرف سب سے حالیہ 20,000
- C) خلاصہ کریں، اور discussion نکالیں، عمومی (allergies, quantities, preferences) structured data اسم رکھیں [درست] verbatim کو exchanges حالیہ
- D) کریں retrieve کے ذریعہ متعلقہ حصہ semantic search کریں اور conversation externally store مکمل

Allergies معلومات محفوظ رکھتی ہے valuable پر سب سے زیادہ cost سب سے کم Hybrid approach: کیوں C (summarization) ہوتا ہے میں compact structured block ایک critical facts جیسے recipe quantities اور exchanges ہوتی ہیں، اور حالیہ discussion summarize عمومی، (سہ بچاتے ہوئے precision loss کے دوران conversational coherence کے لیے verbatim میں Options A اور B dietary information اسم B اور A زیادہ پیچیدہ ہے cooking session ایک D ہیں؛

## سوال 66

ka preferences اور topics پر assistant کے conversations میں reports کرتے ہیں کہ طویل Users: صورتحال رکھتی ہے message pairs صرف آخری 25 implementation حساب کھو دیتا ہے آپ کی موجود

کیا ہے؟ solution سب سے مؤثر

- A) Hybrid approach: messages پرانے حالیہ messages کا خلاصہ کرتے ہوئے حالیہ messages پرانے
- B) vector similarity search پر conversation history مکمل
- C) Window 50 message pairs تک بڑھائیں
- D) آگے جوڑیں running summary کا خلاصہ کریں اور dropped messages میں turn کر

A: Hybrid approach کیوں A محفوظ رکھتی ہے exact recent context کی مسئلہ کے دونوں پہلوؤں کو حل کرتی ہے Hybrid approach کیوں A برقرار compressed representation کی preferences جبکہ پہلو کی (کے لیے) (conversational coherence) miss کو context میں (B) Vector search صرف اسی مسئلہ کو ملتوی کرتا ہے (C) بڑھانا Window رکھتی ہے (D) semantically سے current query کر سکتی ہے جو

## سوال 67

بڑھ جاتی latency سے زیادہ ہوتے ہیں تو 50 turns conversations reports کرتے ہیں کہ جب Users: صورتحال بھی costs اور

بنیادی وجہ کیا ہے؟

- A) شامل ہوتی ہے conversation history کے ساتھ پوری API request کر
- B) Model gradually responses generate کرتا ہے
- C) History سے ساتھ database operations میں بڑھنے کے ساتھ
- D) Model بناتا ہے internal user profile کی ضرورت والا processing زیادہ

A: Claude کی API پر مکمل طور پر stateless — کو request کے messages array میں پوری request بڑھتی ہے، conversation history شامل کرنی ہوتی ہے جیسے جیسے conversation history کے درمیان کوئی Model calls دونوں بڑھاتا ہے cost اور directly processing latency ل جاتی ہے، جو internal state رکھتا ہے (D غلط ہے)

## سوال 68

تک بڑھ گئی ہے جب conversation history 85,000 tokens، بعد weekly sessions: صورتحال: تین مہینوں کے discussions پچھلی assistant کے بارے میں کیا نتیجہ اخذ کیا تھا؟، تو theme کے isolation پوچھتا ہے "م نہ user کرنے کے بجائے عام جوابات دیتا ہے reference

کیا ہے؟ approach سب سے مؤثر

- A) Rolling window truncation
- B) Key conclusions capture کے ہوئے progressive summarization
- C) Relevant exchanges retrieve کے لیے [درست] semantic embeddings کرنے کے لیے
- D) Discussion conclusions mark کے لیے structured XML tags کرنے کے لیے

scale کو discussion □□ جو تین مہینوں کی approach واحد semantic search پر conversation history کیوں C □□ Rolling window کر سکتی □□□ specific relevant exchanges surface پر demand کر سکتی □□ جبکہ truncation (A) history □□ Progressive summarization (B) discussions کا بیشتر حصہ ضائع کر دے گی □□ history (A) truncation ابstractions میں compress □□ کرتی □□ □□ users کھو دیتی □□ جن کا بار □□ میں specific conclusions ، کرتی □□ □□ compress میں abstractions بوجھ □□ ہیں □□

## سوال 69

کرتا ہے، system prompt guidelines میں 10-15 Claude، دوران QA testing: صورتحال  
 اندر 1000 token limits ابھی Conversation آجائی 1000 deviation میں responses لیکن بعد 1000

کیا ؟ solution بہترین

- A) Behavioral guidelines user message کو منتقل کریں
- B) 20 turns conversation شروع کریں
- C) Conversation breakpoints guidelines reinforce والے user-role messages insert [درست] کریں
- D) Non-compliant responses regenerate کو post-response validation استعمال کریں

history کا براہ راست مقابلہ کرتا ہے Behavioral reminders کا periodic injection instruction drift کو regular intervals پر constraints re-establish کرتا ہے Guidelines کو user کو پر Accumulate message کو preventive (D) corrective Post-response validation کم کرتا ہے authority ان کا (A) میں منتقل کرنا شامل کرتی ہے significant latency اور preventive

## سوال 70

□□ teaching methodology اور adaptation rules □□ جو AI tutor 2,800 token-system prompt میں **صورتحال:** آپ کو define 12 □□□ □□□ assistant proficiency levels □□□ کر دیتا □□، بعد 12 turns کرتا □□□

کیا fix سب سے مؤثر

- A) 5–4 turns میں reminders inject کریں
- B) Verbose rules کو proficiency-level adaptation demonstrate کرنے والے few-shot examples سے replace کریں [درست]
- C) Critical rules کو system prompt کے آخر میں رکھیں
- D) Responses evaluate کر کے اگر difficulty level match نہ ہو تو regenerate کریں

**B کیوں:** Declarative rules 2,800 والا token system prompt drift کیونکہ abstract rules vulnerable لی concrete few-shot examples کو Verbose rules کا تقاضا کرتے ہیں reasoning سے model میں turn ر clear کرنا لی match کو model، کریں demonstrate proficiency-level adaptation correct کرنا جو replace ہوتا ہے reliably سے زیادہ abstract instructions میں، turns دیتا ہے —، کئی behavioral patterns

## سوال 71

clarifying کرنا، اور reasoning explain برقرار رکھنا، اپنی enthusiastic tone کو assistant **صورتحال**: آپ کے □  
□ ہونی چاہئیں؟ □ define □ اس behavioral guidelines □ یوں □ □ questions

□ونی چاہئیں؟ define □ان behavioral guidelines □

- A) user message پر prepend کریں
- B) System prompt [درست] میں
- C) assistant message پر
- D) Environment variables میں

**کیوں:** System prompt والی apply میں conversation خاص طور پر پوری persistent behavioral constraints (A) redundant شامل کرنا user message کے لیے ڈیزائن کیا گیا ہے۔ اور guidelines اور constraints overhead (B) redundant statements (C) unreliable model کے کیونکہ assistant message (D) model کے behavior پر اثر نہیں ڈالتے۔ Environment variables (D) model کے behavior پر اثر نہیں ڈالتے۔

## سوال 72

جیسے "یقیناً!" اور "میں مدد کرنے میں خوش ہوں!" رپورٹ کرتے Users repetitive response openings: صورتحال

کیا approach؟ سب سے مؤثر

- A) Direct response opening partial assistant message append [درست] کریں □ ساتھ □
- B) Temperature setting کم کریں □
- C) Greetings responses □ ٹاڈ □ □ لے □ کریں □ post-process کو □
- D) System prompt phrases □ ان □ میں □ شامل □ instructions □ بچہ □ کی □

A greeting generation level پر کرنا prefill جواب کی شروعات سے direct response کو Assistant کیوں: patterns کرنا — model prefill — continue بچاؤ کرنا opening phrases generate کرنا System prompt instructions (D) Post-processing (C) میں reliable مدد کر سکتی ہیں لیکن کم fragile ایک (B) randomness control کرتا ، specific phrase patterns میں ہیں workaround Temperature

## سوال 73

user کو گیا ہے جبکہ package ship کا user کرتا ہے کہ notify کو system آپ کے webhook صورتحال: ایک شامل کرے کہ naturally میں response اس کے اگلے assistant کر رہا ہے آپ چاہتے ہیں کہ actively chat

کیا ؟ approach بہترین

- A) Shipping status کو system prompt میں شامل کریں
- B) synthetic user message بھیجیں
- C) status tool call کو assistant میں turn کرنا
- D) Status update کو user message کے prefix کے طور پر append کریں [درست]

کیے بغیر interrupt کو flow کے طور پر شامل کرنا prefix کے user message کو آگے Status update کیوں D (A) session کرنا System prompt modify کرتا ہے real-time context inject پر natural conversation boundary rebuild کے Synthetic user message کی ضرورت ہے (B) natural dialogue flow کو disrupt کر کے turn کر سکتا ہے (C) events rare جب wasteful اس وقت کرنا tool call force میں

## سوال 74

Assistant 4+ clarifying requests میں "جیس" venue book اکثر "پارٹی کے لیے" Users: صورتحال  
abandonment % پوچھتا ہے، جس سے 35 questions

کرتا ہے؟ improve کو بہترین طریقہ سے approach trade-off کونسا

- A) Hidden defaults کے ساتھ آگے بڑھیں
- B) میں پوچھیں compound message ایک clarifying questions تمام
- C) Assumptions explicitly بیان کریں اور [درست] corrections بڑھیں
- D) Structured intake form استعمال کریں

دیتا ہے جبکہ غلط response کو فوری، مفید user بیان کرنا اور آگے بڑھنا Assumptions explicitly: کیوں C  
کو نہیں بتاتا کہ کیا user (A) Hidden defaults کرنے کی صلاحیت برقرار رکھتا ہے correct کو assumptions  
Structured کا تقاضا کرتی ہے upfront effort سے user پھر بھی (B) Compound question list کیا گیا assume  
form (D) کی بجائے زیادہ شامل کرتا ہے friction کم

## سوال 75

turns rules follow استعمال کرتا ہے ابتدائی assistant contractor-persona system prompt صورتحال: آپ کا  
Conversational length 2,500 tokens صرف دیتا ہے assistant generic advice تک 7 turn کرتا ہے، لیکن

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) System prompts کے لیے initial behavior establish صرف
- B) Turns accumulate کے ساتھ model کی attention ہوتی ہے
- C) Accumulated assistant responses system prompt اثر کو dilute [درست] میں
- D) System prompt صرف ایک بار بھیجا جاتا ہے

System prompt جمع ہوتے ہیں assistant responses میں conversation history کیوں: جیس جیس C  
behavioral constraints کو reflect کرنے والے assistant-generated content بڑھتا ہے proportion کا text کرنے والے  
بجائے اپنے پائلے system prompt instructions پر بھی token lengths چھوٹے Model کم ہوتا جاتا ہے relative  
outputs کرتا ہے compound کو drift، کرتا ہے follow کو زیادہ patterns کے

## سوال 76

کئی Assistant "میں مدد کر سکتے ہیں؟" report کرتے ہیں جیس "کیا آپ requests میں" Users: صورتحال  
abandonment % جس سے 40، (کیا ہے؟ deadline؟ کیا مدد؟ report؟ کون سی) کرتا ہے respond سوالات پوچھ کر  
ہوتا ہے

کیا ہے؟ solution بہترین

- A) Reasonable assumptions کی پیشکش کریں [درست] adjustments بیان کریں، اور explicitly کریں، انہیں
- B) Respond کے ساتھ smaller model کرنے سے پائلے ambiguity classify کریں
- C) Assumptions کریں predefined interpretations بیان کیے بغیر
- D) Assistant تک محدود کریں clarifying question میں ایک turn کو

رکھتے ہیں اور in control کو user کو informed کے ساتھ آگے بڑھنا Reasonable stated assumptions: کیوں A کرتی ہے confuse کو users (C) Silent predefined interpretations کو مکمل طور پر ختم کرتا ہے back-and-forth کی back-and-forth turns بھی (D) One-question limit کے ساتھ match ان کے ارادے سے response میں جب latency اور infrastructure مسئلہ حل کے بغیر core UX (B) Smaller classification model ضرورت ہے شامل کرتا ہے complexity

## عملی مشقیں

### Exercise 1: Multi-tool Agent with Escalation Logic

Goal: tool integration, structured errors, اور escalation کے ساتھ agent loop بنائیں

### Exercise 2: Configuring Claude Code for Team Development

Goal: CLAUDE.md, custom commands, path-specific rules, اور MCP servers configure کریں

### Exercise 3: Structured Data Extraction Pipeline

Goal: JSON schema, validation/retry loops, اور Message Batches API کے ساتھ extraction pipeline بنائیں

### Exercise 4: Designing and Debugging a Multi-agent Research Pipeline

Goal: subagent orchestration, explicit context passing, error propagation, اور source tracking implement کریں

## Appendix: Technologies and Concepts

| Technology       | Key aspects                                                                                                            |
|------------------|------------------------------------------------------------------------------------------------------------------------|
| Claude Agent SDK | agent loops, <code>stop_reason</code> , hooks, <code>Task</code> , <code>allowedTools</code>                           |
| MCP              | servers, tools, resources, <code>isError</code> , <code>.mcp.json</code>                                               |
| Claude Code      | CLAUDE.md, <code>.claude/rules/</code> , <code>.claude/commands/</code> , <code>.claude/skills/</code> , planning mode |
| Claude Code CLI  | <code>-p</code> , <code>--output-format json</code> , <code>--json-schema</code>                                       |
| Claude API       | <code>tool_use</code> , <code>tool_choice</code> , <code>stop_reason</code> , <code>max_tokens</code>                  |

|                        |                                                     |
|------------------------|-----------------------------------------------------|
| Message Batches API    | 50% savings, 24-hour window, <code>custom_id</code> |
| JSON Schema            | required/optional, nullable, enum values            |
| Few-shot prompting     | ambiguous scenarios ❌ ❌ examples                    |
| Prompt chaining        | sequential decomposition                            |
| Context window         | token budget, lost-in-the-middle                    |
| Confidence calibration | field-level scoring, stratified sampling            |

## Out-of-Scope Topics

❌: موضوعات امتحان میں شامل نہیں ہیں

- Claude models کی fine-tuning
- Authentication, billing, یا account management
- implementation کی تفصیلی programming languages مخصوص
- hosting/infrastructure کی MCP servers
- Claude کی internal architecture یا model weights
- Constitutional AI, RLHF, یا safety training
- Embeddings یا vector databases کی implementation details
- Computer use / browser automation
- Vision / image analysis
- Streaming API یا SSE
- Rate limiting اور detailed API cost calculations
- OAuth اور API key rotation details
- Cloud-provider-specific configs
- Performance benchmarks
- Prompt caching implementation details
- Token counting algorithms

## Preparation Recommendations

1. بنائیں agent کو ساتھ ایک Claude Agent SDK
2. کریں configure پر real project کو Claude Code
3. کریں test اور MCP tools design
4. بنائیں Data extraction pipeline
5. کریں Prompt engineering practice
6. سیکھیں Context management patterns

7. Escalation اور human-in-the-loop workflows سمجھیں

8. Practice exam حل کریں